

Interpretables por diseño

Reglas breves, árboles poco profundos y modelos aditivos con componentes controlados.

Interpretabilidad frágil

Un árbol extenso o una regla con numerosas excepciones deja de ser comprensible en la práctica.

Cajas negras

Ensamblajes de árboles, máquinas de vectores soporte con kernel y redes neuronales.

Explicación post-hoc: una aproximación sometida a prueba, no transparencia recuperada

Agnóstica al modelo

Consulta entradas y salidas sin acceder a parámetros internos. Portable entre familias de modelos; solo observa el comportamiento accesible mediante sus consultas.
Ejemplos: LIME, KernelSHAP, Anchors, DiCE.

Específica del modelo

Aprovecha gradientes, activaciones o la estructura de los árboles. Puede ser más eficiente o precisa dentro de una familia, pero es menos transferible.
Ejemplo: TreeSHAP para modelos de árboles.

Agnosticidad y especificidad son decisiones de diseño, no calificaciones de calidad. Si un modelo interpretable ofrece un desempeño adecuado, conviene considerarlo antes que una caja negra con explicación aproximada.