Marco para la Evaluación Multinivel de la Explicabilidad en IA

Integración de Benchmarking Técnico, Protocolo Reproducible (FOM-7) y Taxonomía de Métricas

J. Herrera

2026-04-19

Table of contents

Marco para la Evaluación Multinivel de la Explicabilidad en IA 6

Resumen 7

Abstract 9

Introducción 11

Cuerpo de la Tesis 14

Marco Metodológico 15

Problema de investigación 15
Justificación científica y práctica 17
Objetivos e hipótesis 18
Objetivo general 18
Objetivos específicos 18
Hipótesis o proposiciones de trabajo 19
Metodología general de la investigación 20
Enfoque 20
Tipo de investigación 20
Universo y contexto experimental 21
Muestra de datasets, modelos y métodos XAI 21
Criterios de inclusión y exclusión 22
Variables, dimensiones y métricas 22
Estrategia procedimental 23

Marco teórico específico / fundamentos conceptuales **25**
Estado del arte en XAI e interpretabilidad agnóstica 25
Fundamentos de IA de caja negra 26
Interpretabilidad y explicabilidad 27
Criterios de evaluación de explicaciones 27
Fidelidad 28
Estabilidad 28
Robustez 29
Sparsity / complejidad 29
Coste computacional 29
Alineación causal y sensibilidad contrafactual 29

Marco empírico y diseño experimental **31**
Fases experimentales: EXP1, EXP2 y EXP3 31
Fase de calibración y reproducibilidad (EXP1) 32
Fase de benchmark primario de robustez (EXP2) 34
Fase de validación externa compacta (EXP3) 34
Conjuntos de datos y protocolo de preprocesamiento 35
Descripción del conjunto de datos 35
Carga, limpieza y partición 36
Controles de fuga de datos 37
Diseño factorial del benchmark primario (EXP2) 37
Jerarquía de análisis y unidad inferencial 38
Protocolo de muestreo de instancias y configuración de explicadores 39
Muestreo estratificado por cuadrante de error 39
Configuración de los explicadores 39
Operacionalización de las métricas 40
Fidelidad 40
Estabilidad 40
Parsimonia 41
Brecha de fidelidad 41
Coste computacional 42
Resumen de métricas primarias 42
Protocolo de operación FOM-7 42

Cobertura de artefactos y análisis del impacto de datos faltantes 44
Inventario de cobertura 44
Evaluación cuantitativa del impacto estadístico 45
Plan de inferencia estadística 46
Estudio A: test omnibus de Friedman 46
Localización post-hoc: Nemenyi 47
Wilcoxon pareado: conjuntos de 45 y 75 celdas 48
Control de multiplicidad 48
Resumen del plan estadístico por hipótesis 49
Trazabilidad y reproducibilidad 49

Resultados y discusión **51**
Descripción general de la cobertura analítica 51
Estudio A: Análisis omnibus multimétrico (H1 y H2) 52
H1: Diferencias entre métodos en fidelidad 52
H2: Diferencias entre métodos en estabilidad 54
Estudio B: Análisis pareado SHAP-LIME y trade-off calidad-coste (H3) 56
Diferencias en métricas de calidad 56
Verificación del requisito de multiplicidad 58
Proposición P1: Reproducibilidad del protocolo FOM-7 59
Perfil multidimensional por método 60
SHAP 60
LIME 61
Anchors 62
DiCE 62
Análisis transversal: efecto del modelo base y del tamaño de muestra 63
Efecto del modelo base sobre las métricas 63
Efecto del tamaño de muestra estratificado 64
Discusión 65
Interpretación conjunta de H1, H2 y H3 65
Trade-off calidad-coste y criterios de selección operativa . . 66
Validación externa EXP3: integración con EXP1 y EXP2 . 67

Contribuciones, limitaciones y extensiones 68

Conclusiones **70**
Respuesta al problema de investigación e hipótesis 70
Estudio C: Taxonomía estructurada del espacio de métricas de evaluación XAI 73
Motivación y posicionamiento 73
Los cuatro ejes de la taxonomía 73
Mapeo de las métricas del benchmark a la taxonomía 76
Contribución teórica de la taxonomía 77
Contribuciones científicas 78
Contribución metodológica: protocolo FOM-7 78
Contribución teórica: disociación fidelidad-estabilidad y taxonomía de métricas 79
Contribución aplicada: criterios prescriptivos de selección de métodos XAI 79
Limitaciones del estudio 80
Líneas de investigación futura 81
Síntesis final 83

Referencias **84**

Apéndices **90**
Apéndice A: Detalles del corpus de datos 90
Apéndice B: Configuración de los modelos de caja negra 90
Apéndice C: Prompts utilizados para la evaluación con LLMs . . 90

Marco para la Evaluación Multinivel de la Explicabilidad en IA

Integración de Benchmarking Técnico, Protocolo Reproducible (FOM-7) y Taxonomía de Métricas

Resumen

Esta tesis propone un marco de evaluación multinivel para la Inteligencia Artificial Explicable (XAI) orientado a comparar métodos agnósticos al modelo bajo condiciones de benchmarking controladas y reproducibles. El trabajo responde a la "crisis de evaluación" en XAI articulando tres componentes complementarios: (i) un protocolo de operación reproducible de siete puertas (FOM-7) que conecta diseño experimental, calificación de artefactos e inferencia estadística admisible; (ii) un benchmark cuantitativo multi-métrico sobre datos tabulares reales que evalúa SHAP, LIME, Anchors y DiCE en cinco familias de modelos; y (iii) una taxonomía estructurada del espacio de métricas de evaluación XAI organizada en cuatro ejes (objetivo de evaluación, fuente de evidencia, propiedad de calidad y contexto de tarea).

El estudio empírico se realiza sobre el conjunto Adult (UCI Adult Income) y operacionaliza cinco métricas primarias: fidelidad, estabilidad, parsimonia, brecha de fidelidad (*faithfulness gap*) y coste computacional. La inferencia confirmativa se apoya en comparaciones no paramétricas con control de multiplicidad y en un análisis pareado SHAP–LIME para cuantificar el trade-off calidad–coste. Los resultados muestran diferencias grandes y consistentes entre métodos: SHAP domina en fidelidad y estabilidad en los contextos evaluados, mientras que LIME resulta competitivo cuando la latencia es crítica, a costa de explicaciones estructuralmente inestables. Anchors y DiCE se posicionan como enfoques con objetivos explicativos cualitativamente distintos a la atribución de características. En conjunto, la tesis aporta un protocolo portable y un marco conceptual que permiten

seleccionar métodos XAI en función de objetivos operativos y acumular evidencia de forma reproducible.

Palabras clave: inteligencia artificial explicable (XAI); evaluación multimétrica; benchmarking reproducible; protocolo FOM-7; atribución de características; explicaciones contrafactuales; datos tabulares.

Abstract

This thesis proposes a multilevel evaluation framework for Explainable Artificial Intelligence (XAI) aimed at comparing model-agnostic explainers under controlled and reproducible benchmarking conditions. To address the evaluation fragmentation in XAI, the framework integrates three complementary components: (i) a seven-gate operational protocol (FOM-7) that links experimental design, artifact qualification, and statistically admissible inference; (ii) a multi-metric quantitative benchmark on real-world tabular data evaluating SHAP, LIME, Anchors, and DiCE across five model families; and (iii) a structured taxonomy of XAI evaluation metrics organized along four axes (evaluation target, evidence source, quality property, and task context).

The empirical study uses the Adult (UCI Adult Income) dataset and operationalizes five primary metrics: faithfulness, stability, parsimony, faithfulness gap, and computational cost. Confirmatory inference relies on non-parametric comparisons with multiplicity control and on a paired SHAP–LIME analysis to quantify the quality–cost trade-off. Results show large and consistent differences across methods: SHAP dominates in faithfulness and stability in the evaluated settings, whereas LIME becomes attractive when latency constraints dominate, at the cost of structurally unstable explanations. Anchors and DiCE address qualitatively different explanatory objectives than feature attribution. Overall, the thesis contributes a portable protocol and a conceptual framework to support operationally grounded XAI method selection and reproducible evidence accumulation.

Keywords: explainable AI (XAI); multi-metric evaluation; reproducible benchmarking; FOM-7 protocol; feature attribution; counterfactual explanations; tabular data.

Introducción

El rápido avance de la inteligencia artificial (IA), particularmente en el ámbito del aprendizaje profundo y los modelos complejos de aprendizaje automático, ha transformado radicalmente la capacidad predictiva en dominios tan diversos como la atención médica, las finanzas y los sistemas autónomos. Sin embargo, esta evolución tecnológica ha traído consigo una problemática fundamental: la naturaleza de "caja negra" de estos modelos, la cual plantea serias preocupaciones respecto a la confianza, la transparencia y la responsabilidad algorítmica. En este escenario, la interpretabilidad emerge no solo como un desafío técnico de primer orden, sino como un requisito ético y legal indispensable para el despliegue de soluciones en el mundo real. Para abordar esta opacidad, los métodos de explicación agnósticos al modelo —tales como LIME (Ribeiro 2016), SHAP (Lundberg 2017) y Anchors (Ribeiro 2018)— han ganado protagonismo al intentar proporcionar explicaciones *post-hoc* sin necesidad de alterar los componentes internos del modelo, facilitando así la detección de sesgos y la validación de resultados en aplicaciones críticas.

A pesar de su potencial, los enfoques actuales de explicabilidad adolecen de limitaciones significativas que restringen su aplicabilidad práctica. En primer lugar, la comunidad científica enfrenta lo que se ha denominado una "crisis de evaluación", caracterizada por una proliferación de métricas inconexas que a menudo generan resultados duplicados o contradictorios (Pawlicki et al. 2024). Revisiones sistemáticas recientes (Abdul Kadir et al. 2023) revelan que, a pesar del auge de la disciplina, solo una pequeña fracción del corpus de investigación —aproximadamente el 14%— incorpora evaluaciones cuantitativas rigurosas. Esta carencia de estándares se

ve agravada por la falta de consenso formal sobre las propiedades fundamentales de una "buena" explicación, lo que dificulta la comparación objetiva entre métodos (Canha et al. 2025; Nizam and Zafar 2023). La ausencia de criterios consensuados provoca que, a menudo, se ignore la "validez semántica" de la explicación, priorizando métricas matemáticas proxy que no siempre logran capturar el juicio comprensible para un experto humano.

A los desafíos de estandarización se suman debilidades técnicas críticas en los marcos de evaluación vigentes. Estudios recientes han identificado que muchas de las métricas de fidelidad tradicionales sufren del problema de datos "fuera de la distribución" (Out-of-Distribution o OOD), donde la eliminación o perturbación de características genera instancias que el modelo original nunca encontró durante su entrenamiento, invalidando así sus respuestas y las puntaciones de fiabilidad resultantes (Zheng et al. 2025). Si bien han surgido ecosistemas de benchmarking integrales como Quantus (Hedström et al. 2023) y OpenXAI (Agarwal et al. 2022) para intentar unificar el campo, todavía persiste una brecha significativa en la evaluación de la coherencia multidimensional, que debe abarcar tanto la precisión técnica como la utilidad percibida por el usuario (Bhattacharya and Verbert 2024).

Bajo esta premisa, la presente investigación busca cerrar esta brecha mediante el desarrollo y la comparación de métodos de explicación agnósticos que sean simultáneamente fiables, interpretables y computacionalmente eficientes. El estudio se propone introducir un marco de evaluación multinivel que trascienda las métricas tradicionales, integrando dimensiones de alineación causal y medidas de robustez para proporcionar una comprensión más holística de la calidad de la explicabilidad. Esta propuesta es de alta relevancia tanto para la academia como para la industria, pues se alinea con las crecientes exigencias regulatorias y éticas que demandan una gobernanza de la IA más transparente y auditable. El objetivo final es contribuir al campo de la IA explicable (XAI) mediante un enfoque escalable y adaptativo, asegurando que los modelos de IA no solo alcancen

niveles de precisión sobresalientes, sino que sean también profundamente confiables y plenamente comprendidos por sus usuarios.

Para alcanzar estos objetivos, el documento se estructura de manera lógica a través de cinco capítulos fundamentales. Tras esta introducción, el **Capítulo 1** establece el marco metodológico y las hipótesis de trabajo. El **Capítulo 2** detalla los fundamentos conceptuales y el estado del arte de las técnicas agnósticas. El **Capítulo 3** detalla el diseño experimental de las fases de benchmarking y validación. El **Capítulo 4** expone y discute los resultados obtenidos, mientras que el **Capítulo 5** sintetiza las conclusiones generales, las contribuciones al área y las futuras líneas de investigación que se derivan de este estudio.

Cuerpo de la Tesis

Marco Metodológico

Este capítulo establece el posicionamiento investigativo de la tesis. Se articula en cuatro ejes: el problema de investigación que motiva el trabajo, la justificación de su relevancia científica y práctica, los objetivos e hipótesis formales que orientan la indagación empírica, y la metodología general que estructura el diseño de los estudios. La exposición detallada de los fundamentos conceptuales —incluyendo las bases técnicas de los métodos de explicabilidad y los criterios de evaluación— se desarrolla en el Capítulo 2.

Problema de investigación

La Inteligencia Artificial Explicable (XAI) ha consolidado un ecosistema de métodos *post-hoc* agnósticos al modelo cuya adopción en dominios de alto riesgo crece de forma sostenida (Adadi 2018; Arrieta 2019a; Angelov 2021; Schwalbe 2023; Ali 2023; Belle 2021; Linardatos 2020; Saarela 2024; Malwade 2023). Sin embargo, la capacidad del campo para *evaluar* esos métodos de manera comparativa, rigurosa y reproducible no ha avanzado al mismo ritmo (Doshi-Velez 2017; Samek 2019; Canha et al. 2025). En la práctica, esta tensión se observa incluso en explicadores locales ampliamente utilizados —como LIME y SHAP— cuyo uso extensivo contrasta con la variabilidad de criterios de evaluación reportados entre estudios (Ribeiro 2016; Lundberg 2017; Pawlicki et al. 2024). Revisiones sistemáticas recientes identifican una marcada proliferación de métricas inconexas,

inconsistencia en los criterios de inclusión de instancias y ausencia de protocolos que conecten la ejecución experimental con la inferencia estadística admisible (Pawlicki et al. 2024; Abdul Kadir et al. 2023; Altukhi 2025; Bhattacharya and Verbert 2024; Lipton 2018). Como resultado, los estudios publicados son frecuentemente inconmensurables entre sí y no permiten la acumulación sistemática de evidencia (Doshi-Velez 2017; Canha et al. 2025).

La raíz técnica de este problema es doble. Por un lado, las métricas de fidelidad —las más ampliamente utilizadas— no capturan dimensiones igualmente relevantes para el despliegue práctico: la estabilidad ante perturbaciones de entrada, la parsimonia de las explicaciones producidas y el coste computacional por instancia (Bhattacharya and Verbert 2024; Abdul Kadir et al. 2023; Canha et al. 2025; **brown2023?**). Por otro lado, muchas de estas métricas sufren del problema de datos fuera de la distribución (*Out-of- Distribution*, OOD): la perturbación de características genera instancias que el modelo nunca encontró durante el entrenamiento, invalidando las puntuaciones de fidelidad resultantes (n.d.; Zheng et al. 2025). La disponibilidad de herramientas de benchmarking como Quantus (Hedström et al. 2023) y OpenXAI (Agarwal et al. 2022) ha mejorado la estandarización de la medición, pero no resuelve la ausencia de un protocolo de operación que discipline la trazabilidad de artefactos y la corrección de multiplicidad en la inferencia (Doshi-Velez 2017; Canha et al. 2025).

El problema de investigación de esta tesis se formula en los siguientes términos: **¿En qué medida difieren los métodos de explicabilidad agnósticos al modelo en un conjunto multidimensional de métricas de calidad bajo condiciones de benchmarking controladas y reproducibles, y qué criterios técnicos permiten orientar su selección en función de los objetivos operativos?**

Justificación científica y práctica

Desde el punto de vista científico, esta investigación responde a una necesidad metodológica identificada de forma recurrente en la literatura: la falta de un protocolo unificado que conecte el diseño experimental, la calificación de artefactos y la inferencia estadística controlada (Hedström et al. 2023; Agarwal et al. 2022; Zheng et al. 2025; Doshi-Velez 2017; Allen 2024). La formalización de ese protocolo como un método de operación de siete puertas (FOM-7) constituye en sí misma una contribución al campo de la metodología de evaluación en XAI (Canha et al. 2025). Complementariamente, la construcción de una taxonomía estructurada del espacio de métricas de evaluación proporciona un marco conceptual que organiza las brechas de constructo actualmente dispersas en la literatura (Pawlicki et al. 2024; Abdul Kadir et al. 2023; Nizam and Zafar 2023; Marcinkevičs 2023; Schwalbe 2023).

Desde el punto de vista práctico, los sistemas de IA se despliegan de forma creciente en dominios donde la explicabilidad no es opcional, sino un requisito normativo y ético (Mittelstadt 2019; Floridi 2018; Hassija 2023; Ali 2023). En este contexto, los profesionales y organizaciones necesitan criterios técnicos fundamentados que orienten la selección de métodos XAI en función de objetivos operativos concretos —p. ej., alta fiabilidad auditora frente a baja latencia de respuesta— y de las preferencias y expectativas de los usuarios (Murdoch 2019; Rudin 2022; Belle 2021; Tripathy 2024; **brown2023?**; Nussberger 2022). Esta tesis provee esa orientación a través de un análisis empírico pareado, reproducible y estadísticamente riguroso sobre datos tabulares reales.

Objetivos e hipótesis

Objetivo general

Desarrollar y validar un marco de evaluación multinivel y reproducible para métodos de explicabilidad agnósticos al modelo, que integre un protocolo de benchmarking cuantitativo multi-métrico y un análisis taxonómico estructurado, con el fin de establecer criterios técnicamente rigurosos para la selección y comparación de métodos XAI en contextos de datos tabulares.

Objetivos específicos

1. Diseñar y formalizar un protocolo de benchmarking reproducible (FOM-7) que garantice trazabilidad entre artefactos de ejecución, calificación de evidencia e inferencia estadística admisible (Canha et al. 2025; Hedström et al. 2023; Agarwal et al. 2022).
2. Evaluar comparativamente cuatro métodos agnósticos —SHAP, LIME, Anchors y DiCE— sobre cinco familias de modelos en el conjunto de datos UCI Adult Income, utilizando un conjunto multidimensional de métricas: fidelidad, estabilidad, parsimonia, brecha de fidelidad y coste computacional. (Lundberg 2017; Ribeiro 2016, 2018; Mothilal 2020; Wachter 2017; **kohavi1996?**; Abdul Kadir et al. 2023; Bhattacharya and Verbert 2024)
3. Cuantificar las diferencias en el trade-off calidad-coste entre LIME y SHAP mediante pruebas estadísticas pareadas sobre celdas coincidentes de modelo, semilla y tamaño de muestra.
4. Caracterizar el perfil de reproducibilidad del protocolo de benchmarking mediante el análisis de la dispersión métrica bajo ejecuciones repetidas con semillas distintas.

5. Construir una taxonomía estructurada del espacio de métricas de evaluación XAI organizada en cuatro ejes —objetivo de evaluación, fuente de evidencia, propiedad de calidad y contexto de tarea— que sirva de marco conceptual integrador para los Estudios A y B (Abdul Kadir et al. 2023; Pawlicki et al. 2024; Nizam and Zafar 2023; Marcinkevičs 2023; Schwalbe 2023).

Hipótesis o proposiciones de trabajo

Las hipótesis estadísticas formales se estructuran en torno a los tres ejes confirmatorios de la investigación empírica.

H1 — Diferencias globales entre métodos (fidelidad)

$H_{0,1}$: No existen diferencias significativas entre los métodos XAI en la métrica de fidelidad bajo el diseño de bloques emparejados.

$H_{1,1}$: Al menos un par de métodos difiere significativamente en fidelidad.

H2 — Diferencias globales entre métodos (estabilidad)

$H_{0,2}$: No existen diferencias significativas entre los métodos XAI en la métrica de estabilidad bajo el diseño de bloques emparejados.

$H_{1,2}$: Al menos un par de métodos difiere significativamente en estabilidad.

H3 — Trade-off calidad-coste SHAP vs. LIME

$H_{0,3}$: SHAP y LIME no difieren en las métricas de calidad ni en el coste computacional sobre celdas pareadas.

$H_{1,3}$: SHAP y LIME difieren significativamente en al menos una métrica de calidad o en el coste computacional sobre celdas pareadas.

P1 — Reproducibilidad del protocolo (proposición)

El protocolo FOM-7 produce un coeficiente de variación (CV) inferior al 15% en las métricas primarias bajo ejecuciones repetidas con semillas distintas en condiciones de configuración idéntica, lo que constituye evidencia de estabilidad operativa del benchmarking.

Las hipótesis H1 y H2 se contrastan mediante la prueba de Friedman con bloques (g, n) y localización *post-hoc* de Nemenyi. La hipótesis H3 se contrasta mediante pruebas de Wilcoxon bilaterales pareadas sobre 75 celdas coincidentes SHAP-LIME, con corrección de Holm-Bonferroni para multiplicidad (**friedman1937?**; **demsar2006?**; **nemenyi1963?**; **wilcoxon1945?**).

Metodología general de la investigación

Enfoque

Esta investigación adopta un enfoque cuantitativo-empírico con componente teórico-taxonómico. El núcleo empírico de los Estudios A y B descansa en el análisis estadístico de métricas computadas sobre experimentos controlados y reproducibles, siguiendo una lógica hipotético-deductiva. El componente taxonómico del Estudio C —que actúa como puente conceptual integrador— adopta una metodología de revisión estructurada con codificación explícita de dimensiones, siguiendo protocolos de síntesis narrativa rigurosa (Linardatos 2020; Gilpin 2018; Schwalbe 2023; Abdul Kadir et al. 2023).

Tipo de investigación

Los Estudios A y B corresponden a investigación comparativa-experimental no intervencional: los métodos XAI son los factores de tratamiento, los modelos predictivos son el contexto experimental y las métricas de calidad son las variables de resultado. El Estudio

C corresponde a una revisión sistemática estructurada con propósito taxonómico y de síntesis de brechas de constructo en el campo de la evaluación XAI.

Universo y contexto experimental

El universo experimental está constituido por el conjunto de problemas de clasificación tabular supervisada en los que es necesario generar explicaciones *post-hoc* locales mediante métodos agnósticos al modelo. El contexto operativo se acota al conjunto de datos Adult (UCI Adult Income) (**kohavi1996?**), que contiene 48,842 instancias, 14 características (numéricas y categóricas) y una variable binaria de predicción (ingreso anual superior o inferior a 50,000 USD). Este conjunto es ampliamente utilizado en estudios de benchmarking XAI, lo que facilita la comparación externa de resultados y la verificación de reproducibilidad (Agarwal et al. 2022; Hedström et al. 2023; Canha et al. 2025).

Muestra de datasets, modelos y métodos XAI

El diseño experimental adopta una estructura factorial cruzada. Las familias de modelos predictivos son: regresión logística (`logreg`), bosque aleatorio (`rf`) (Breiman 2001), *gradient boosting* XGBoost (`xgb`), máquina de vectores soporte (`svm`) y perceptrón multicapa (`mlp`). Los métodos de explicabilidad evaluados son SHAP (Lundberg 2017), LIME (Ribeiro 2016), Anchors (Ribeiro 2018) y DiCE (Mothilal 2020; Wachter 2017). El tamaño de muestra por estrato se varía en tres niveles: $N \in \{50, 100, 200\}$. Cada celda del diseño se replica con cinco semillas de aleatoriedad: $s \in \{42, 123, 456, 789, 999\}$. El tamaño planificado del benchmark primario (Estudio A) es $5 \times 4 \times 5 \times 3 = 300$ ejecuciones; el análisis pareado LIME-SHAP (Estudio B) opera sobre 75 celdas coincidentes.

Criterios de inclusión y exclusión

Criterios de inclusión:

- Artefactos de resultado (`results.json`) con esquema completo y valores numéricos válidos en todas las métricas primarias.
- Ejecuciones pertenecientes al benchmark primario de robustez (EXP2), cuya configuración ha sido congelada antes del inicio de la inferencia confirmativa.
- Celdas para las que existen artefactos en ambos métodos comparados (SHAP y LIME) para el análisis pareado del Estudio B.

Criterios de exclusión:

- Artefactos vacíos o con esquema incompatible detectados en la auditoría de integridad (puerta 3 del protocolo FOM-7).
- Ejecuciones pertenecientes a la fase de calibración (EXP1), que tienen rol de reproducibilidad y no se emplean para inferencia confirmativa.
- Reconstrucciones sintéticas de artefactos faltantes; únicamente se acepta como excepción la superposición de recuperación documentada sobre las celdas `mlp_shap`/`svm_shap`.

Variables, dimensiones y métricas

Las **variables independientes** del diseño son: familia de modelo (g), método XAI (k), semilla de aleatoriedad (s) y tamaño de muestra por estrato (n). Las **variables dependientes** son cinco métricas primarias:

- **Fidelidad**: correlación entre los pesos de importancia asignados por el explicador y el efecto observado al enmascarar las características de mayor peso (dirección: mayor es mejor).

- **Estabilidad**: similitud coseno media entre explicaciones generadas sobre instancias perturbadas con ruido gaussiano (dirección: mayor es mejor).
- **Parsimonia** (*sparsity*): proporción de características activas en la explicación (dirección: menor es mejor).
- **Brecha de fidelidad** (*faithfulness gap*): diferencia en la salida del modelo entre la instancia original y la instancia con las características principales enmascaradas (dirección: mayor es mejor).
- **Coste computacional**: tiempo de ejecución en milisegundos por instancia (dirección: menor es mejor).

La unidad de análisis inferencial es la ejecución agregada a nivel de bloque (g, n), evitando la pseudorreplicación a nivel de instancia.

La definición operativa de estas dimensiones y sus modos de medición sigue las taxonomías y recomendaciones recientes de evaluación multi-métrica para XAI (Abdul Kadir et al. 2023; Bhattacharya and Verbert 2024; Canha et al. 2025; Zheng et al. 2025).

Estrategia procedimental

La estrategia procedimental se organiza en torno al protocolo FOM-7 (*Framework Operation Method*, siete puertas), derivado de los requisitos de benchmarking reproducible identificados en la literatura (Canha et al. 2025; Agarwal et al. 2022; Hedström et al. 2023) y de los modos de fallo observados durante la fase de calibración piloto.

Las siete puertas secuenciales son:

1. **Congelación del protocolo**: bloqueo de versiones de código, configuraciones, factores y plan de inferencia antes de las ejecuciones confirmativas.
2. **Ejecución por lotes controlada**: ejecución desde manifiestos declarativos con semillas fijas y registro del contexto de tiempo de ejecución.

3. **Auditoría de integridad de artefactos**: detección y exclusión de salidas malformadas, vacías o con esquema incompatible.
4. **Armonización a tablas listas para el análisis**: estandarización de claves y campos de métricas en tablas de inferencia deterministas.
5. **Exportación inferencial**: generación determinista de tablas omnibus y de pruebas pareadas a partir exclusivamente de entradas calificadas.
6. **Perfilado de reproducibilidad**: cuantificación de la dispersión entre ejecuciones y del comportamiento del coeficiente de variación en configuraciones replicadas.
7. **Reporte con trazabilidad de afirmaciones**: las afirmaciones inferenciales solo se permiten cuando todas las puertas previas están satisfechas y son trazables a artefactos fuente.

La secuencia experimental distingue dos cohortes de evidencia con roles diferenciados: la etapa de calibración y reproducibilidad (EXP1), destinada a la verificación de implementación y al perfilado de dispersión; y el benchmark primario de robustez (EXP2), destinado a la inferencia confirmativa. Esta separación reduce la contaminación entre actividades exploratorias y afirmaciones confirmativas, en línea con las recomendaciones de disciplina de partición de evidencia discutidas en trabajos recientes sobre fidelidad de evaluación (Zheng et al. 2025).

Marco teórico específico / fundamentos conceptuales

Estado del arte en XAI e interpretabilidad agnóstica

El campo de la Inteligencia Artificial Explicable (XAI) ha experimentado una expansión sin precedentes en la última década, consolidándose como un pilar crítico para la adopción de modelos de caja negra en sectores de alta responsabilidad. Las revisiones sistemáticas más recientes (Abdul Kadir et al. 2023; Canha et al. 2025) coinciden en que, si bien la literatura ha producido un crecimiento asintótico en el número de algoritmos propuestos —destacando métodos líderes como LIME (Ribeiro 2016), SHAP (Lundberg 2017) y Anchors (Ribeiro 2018)—, el desarrollo de protocolos de evaluación estandarizados no ha seguido el mismo ritmo. De hecho, un análisis basado en la metodología PRISMA realizado por Abdul Kadir et al. (2023) revela que, a pesar de la madurez percibida del área, solo una fracción marginal de la producción científica (estimada en un 14%) incorpora marcos de evaluación cuantitativa rigurosos, limitándose mayoritariamente a validaciones cualitativas o anecdóticas.

Esta fragmentación ha dado lugar a lo que Pawlicki et al. (2024) define como una proliferación de métricas inconexas, donde la duplicidad de criterios y la falta de consenso sobre las propiedades fundamentales de una explicación (como la fidelidad, la estabilidad y la robustez) dificultan la comparación objetiva entre aproximaciones. Investigaciones contemporáneas (Bhattacharya and Verbert 2024; Nizam and Zafar 2023) argumentan que

la falta de un estándar unificado impide valorar la explicabilidad de manera multidimensional, ignorando a menudo el hecho de que los sistemas de IA modernos no solo requieren precisión técnica, sino también validez semántica para sus destinatarios humanos. En respuesta a este vacío, han surgido ecosistemas de benchmarking integrales como Quantus (Hedström et al. 2023) y OpenXAI (Agarwal et al. 2022), los cuales intentan sistematizar el proceso de quantificación mediante toolkits automatizados que agrupan métricas por afinidad lógica. Sin embargo, como señala Zheng et al. (2025), incluso estos marcos enfrentan retos técnicos significativos, como la inestabilidad de las métricas ante datos fuera de la distribución (OOD), lo que subraya la necesidad de seguir evolucionando hacia marcos de evaluación multinivel y más robustos, tal como se propone en el presente estudio.

Fundamentos de IA de caja negra

Para comprender el estado actual de la XAI, es imperativo analizar la naturaleza técnica de la "caja negra" (*black-box models*). La evolución de la IA ha pasado de modelos estadísticos transparentes —como la regresión lineal o árboles de decisión simples— a sistemas cuya lógica interna es inescrutable debido a su altísima dimensionalidad y no linealidad. Los modelos de ensamble (Random Forest, XGBoost) y las Redes Neuronales Profundas (DNN) logran niveles de precisión sobresalientes sacrificando la interpretabilidad directa. Esta opacidad no es un fallo de diseño, sino una consecuencia de la complejidad requerida para capturar patrones en datos no estructurados. Como señalan Canha et al. (2025) y Pawlicki et al. (2024), esto genera un "dilema de confianza" donde el usuario debe aceptar una decisión sin acceso a su proceso deductivo, marcando el punto de partida para las técnicas de explicabilidad agnóstica.

Interpretabilidad y explicabilidad

A pesar de que los términos "interpretabilidad" y "explicabilidad" se utilizan a menudo como sinónimos en la literatura técnica, revisiones sistemáticas de gran escala destacadas por Abdul Kadir et al. (2023) destacan una falta de consenso terminológico que fragmenta el campo. Para los propósitos de este marco multinivel, es fundamental establecer una distinción operativa basada en el destinatario final de la información: el ser humano. Mientras que la interpretabilidad se asocia frecuentemente con la transparencia intrínseca de los mecanismos internos de un modelo, la explicabilidad emerge como un concepto que busca traducir esa complejidad en un lenguaje comprensible para el usuario (Canha et al. 2025).

Siguiendo la propuesta de (**linardatos2021?**), se define la interpretabilidad como la capacidad de discernir la mecánica interna de un sistema sin necesidad de conocer el "porqué" profundo de cada decisión, conectando primordialmente con la intuición técnica. Por el contrario, la explicabilidad añade una "capa de razonamiento" (*reasoning layer*) sobre los mecanismos técnicos para clarificar el proceso lógico que condujo a una salida específica (Canha et al. 2025). Esta distinción es especialmente relevante para esta tesis, ya que justifica la necesidad de no solo evaluar la "fidelidad" al modelo (parámetro técnico), sino también la "coherencia semántica" (capa de razonamiento humano) sustentada por criterios multidimensionales (Bhattacharya and Verbert 2024).

Criterios de evaluación de explicaciones

La evaluación de la calidad de una explicación es un proceso multidimensional que requiere la cuantificación de diversas propiedades funcionales. A continuación, se detallan los criterios técnicos fundamentales adoptados en este estudio, sustentados en la jerarquía funcional propuesta por Canha et al. (2025) y los marcos de benchmarking de Agarwal et al. (2022).

Fidelidad

La fidelidad (*fidelity*) mide el grado en que un método de explicación logra representar el verdadero proceso deductivo del modelo de caja negra. Siguiendo la definición de Canha et al. (2025), esta se operacionaliza a menudo como el "acuerdo del sustituto" (*surrogate agreement*), formulado como:

$$m_{fid} = 1 - \frac{\sum_{i=1}^{N} |b(x_i) - s(x_i)|}{N \cdot \max(b(x))}$$

Donde $b(x)$ representa la salida del modelo de caja negra y $s(x)$ la del modelo sustituto o aproximación local. Es vital distinguir la fidelidad de la fehaciencia (*faithfulness*), ya que un modelo puede ser fiel en su mimetismo predictivo pero no necesariamente fehaciente en capturar la lógica causal subyacente (Zheng et al. 2025).

Estabilidad

La estabilidad evalúa la consistencia de las explicaciones ante variaciones mínimas en los datos de entrada que no alteran la predicción del modelo. Se formaliza comúnmente mediante la Estabilidad de Entrada Relativa (RIS), que estima la sensibilidad del explicador ante perturbaciones en el vecindario de x (Agarwal et al. 2022):

$$RIS = \max_{x'} \frac{||ex(x) - ex(x')||}{||x - x'||}$$

Donde $ex(x)$ es la importancia de características generada para la instancia x. Una RIS elevada señala una fragilidad técnica, indicando que cambios imperceptibles en los datos pueden generar interpretaciones contradictorias.

Robustez

A diferencia de la estabilidad, la robustez se enfoca en la resistencia del explicador ante ataques adversarios o cambios significativos en la distribución. Como identifica Zheng et al. (2025), muchas métricas tradicionales fallan al operar con datos "fuera de la distribución" (OOD), por lo que la robustez técnica implica garantizar que el explicador mantenga su validez incluso cuando el modelo enfrenta instancias atípicas.

Sparsity / complejidad

La complejidad de una explicación debe estar alineada con las capacidades cognitivas humanas. Canha et al. (2025) recurre a la "Ley de Miller" para fundamentar este criterio, sugiriendo que el tamaño óptimo de una explicación informativa debe mantenerse en un rango de 7 ± 2 elementos resaltados. Una explicación con baja cardinalidad (alta *sparsity*) es preferible para reducir la carga cognitiva sin sacrificar la información crítica.

Coste computacional

La eficiencia computacional es un criterio pragmático indispensable. Existe una compensación (*trade-off*) intrínseca entre la fidelidad de métodos como KernelSHAP —que requieren miles de evaluaciones del modelo— y la rapidez de aproximaciones lineales como LIME. Este estudio adopta métricas de latencia de inferencia para valorar la viabilidad del despliegue bajo demanda.

Alineación causal y sensibilidad contrafactual

Finalmente, se introduce la alineación causal, que evalúa si las características identificadas corresponden a relaciones lógicas reales en el dominio

de aplicación. Este criterio se complementa con la sensibilidad contrafactual, que responde a cambios mínimos necesarios para invertir la decisión del modelo, proporcionando una validación semántica que trasciende la métrica puramente matemática (Bhattacharya and Verbert 2024; Reif et al. 2024).

Marco empírico y diseño experimental

Este capítulo describe el diseño empírico de los estudios que conforman el núcleo cuantitativo de la tesis: el benchmark multinivel de métodos agnósticos (Estudio A, Paper A), la comparación pareada enfocada entre LIME y SHAP (Estudio B, Paper B) y la validación externa compacta EXP3. Los dos primeros estudios comparten el mismo pipeline experimental, el mismo conjunto de datos Adult y los mismos artefactos de modelo, y se distinguen por el alcance del análisis inferencial: Estudio A evalúa los cuatro métodos sobre el diseño factorial completo; Estudio B restringe la inferencia confirmativa al subconjunto pareado LIME-SHAP. EXP3 reutiliza el contrato operativo y el paquete de métricas para evaluar portabilidad en Breast Cancer y German Credit, sin incorporarse al contraste confirmativo de EXP2. El capítulo se organiza en ocho secciones: las fases experimentales (EXP1, EXP2 y EXP3), los conjuntos de datos y protocolos de preprocesamiento, el diseño factorial, las configuraciones de los explicadores, la operacionalización de las métricas, el protocolo FOM-7, el análisis de cobertura de artefactos, y el plan de inferencia estadística. Las amenazas a la validez y el inventario de recursos de reproducibilidad figuran en el Apéndice A.

Fases experimentales: EXP1, EXP2 y EXP3

El diseño experimental distingue dos cohortes de evidencia con roles diferenciados, siguiendo el principio de separación entre actividades de cali-

bración y afirmaciones confirmativas (Hedström et al. 2023; Zheng et al. 2025).

Fase de calibración y reproducibilidad (EXP1)

La Fase EXP1 tiene por objetivos: verificar la correcta implementación del pipeline experimental, entrenar y congelar los artefactos de modelo compartidos por todos los explicadores en EXP2, y generar un perfil de reproducibilidad sobre configuraciones replicadas que permita cuantificar la dispersión métrica esperada bajo variación de semilla.

EXP1 opera sobre dos familias de modelos —bosque aleatorio (`rf`) y XGBoost (`xgb`)— y dos métodos explicadores —SHAP (modo árbol) y LIME— formando una cohorte de 75 ejecuciones planificadas. De estas, 66 resultaron analizables (88.0% de cobertura). Los modelos entrenados en EXP1 se congelan como artefactos repositorio bajo `experiments/exp1_adult/models/` y son reutilizados sin reentrenamiento en EXP2, de modo que cualquier diferencia observada entre métodos en la fase primaria es atribuible al explicador y no a variación en el modelo subyacente.

El rendimiento predictivo de los cinco modelos entrenados en EXP1 y evaluados sobre el conjunto de prueba (9,758 instancias, semilla 42) se muestra en la Tabla 3.1. Los valores fueron extraídos directamente de los archivos `experiments/exp1_adult/models/*/metrics.json` del repositorio.

Table 1: Rendimiento predictivo de los modelos en el conjunto de prueba (n = 9,758, semilla 42). Valores extraídos de `models/*/metrics.json`. XGBoost lidera en todas las métricas; el perceptrón multicapa presenta el AUC-ROC más bajo pero supera el umbral de inclusión de 0.88.

Modelo	Exactitud	Precisión	Recall	F1	AUC-ROC
Regresión logística (`logreg`)	0.849	0.842	0.849	0.844	0.903
Bosque aleatorio (`rf`)	0.854	0.849	0.854	0.851	0.902
XGBoost (`xgb`)	**0.870**	**0.865**	**0.870**	**0.865**	**0.926**
Máquina de vectores soporte (`svm`)	0.856	0.849	0.856	0.849	0.898
Perceptrón multicapa (`mlp`)	0.840	0.833	0.840	0.835	0.885

Todos los modelos superan los umbrales de inclusión definidos en el protocolo: exactitud ≥ 0.83 y AUC-ROC ≥ 0.88. Esta dispersión inter-modelo es intencional: un benchmark robusto debe evaluar explicadores sobre modelos de distinta complejidad y tipo de frontera de decisión, incluyendo modelos lineales (logreg), de conjuntos de árboles (rf, xgb), con kernel (svm) y neuronales (mlp).

El perfilado de reproducibilidad de EXP1 establece que las métricas de calidad presentan coeficientes de variación inferiores al 9% bajo variación de semilla: $\mathrm{CV}_F \leq 0.063$, $\mathrm{CV}_S \leq 0.083$, $\mathrm{CV}_P \leq 0.044$, $\mathrm{CV}_{\Delta_k} \leq 0.036$. El coste computacional exhibe mayor variabilidad ($\mathrm{CV}_C \leq 0.225$ para SHAP con kernel), lo que implica que los rankings de calidad son sustancialmente más reproducibles que las estimaciones de latencia. EXP1 **no** contribuye a la inferencia confirmativa de EXP2 ni a las hipótesis H1-H3.

Fase de benchmark primario de robustez (EXP2)

La Fase EXP2 es la cohorte de evidencia confirmativa. Expande EXP1 a los cinco modelos y cuatro métodos explicadores, con cinco semillas y tres tamaños de muestra, bajo el protocolo FOM-7 descrito en la Sección 3.6. Los resultados de EXP2 son la fuente exclusiva de las afirmaciones estadísticas inferenciales de los Estudios A y B.

Fase de validación externa compacta (EXP3)

La Fase EXP3 se añade como capa de validez externa tabular. Su objetivo no es replicar el diseño factorial completo de EXP2, sino comprobar si el mismo contrato de ejecución, persistencia de artefactos, métricas primarias y reglas de calificación pueden operar fuera de UCI Adult Income. Por esta razón, EXP3 se interpreta como evidencia de portabilidad y no como una nueva cohorte confirmativa para las hipótesis H1-H3.

EXP3 utiliza dos conjuntos tabulares adicionales:

- `breast_cancer`: dominio biomédico, pequeño y de baja fricción computacional.
- `german_credit`: dominio socioeconómico y de riesgo crediticio.

El diseño EXP3 es:

$$2 \text{ datasets} \times 2 \text{ modelos} \times 2 \text{ explicadores} \times 3 \text{ semillas} \times 1 \text{ tamaño de muestra} = 24 \text{ ejecuciones}$$

Los factores son:

- datasets: `breast_cancer`, `german_credit`;
- modelos: `rf`, `xgb`;
- explicadores: `shap`, `anchors`;
- semillas: `42`, `123`, `456`;
- tamaño de muestra: `n = 100`.

La elección de SHAP y Anchors preserva heterogeneidad metodológica: SHAP representa atribución densa de características y Anchors representa reglas compactas IF-THEN. LIME y DiCE no se incluyen para mantener EXP3 como paquete compacto y evitar convertirlo en un segundo EXP2. Los resultados completos se integran mediante `scripts/integrate_experiment_evidence.py`, que genera el paquete `outputs/analysis/integrated_evidence/` con tablas normalizadas, fragmentos de tesis y notas de integración para Paper A/B/C.

EXP3 completó `24 / 24` ejecuciones planificadas. En el análisis estadístico, sus métricas se reportan como resumen descriptivo y evidencia de validez externa. No se agregan a los bloques Friedman de EXP2 ni a la prueba pareada SHAP-LIME de Paper B.

Conjuntos de datos y protocolo de preprocesamiento

Descripción del conjunto de datos

Ambos estudios utilizan el conjunto de datos UCI Adult Income (Breiman 2001; **kohavi1996?**), ampliamente empleado en benchmarking de XAI por su estructura tabular heterogénea, su variable objetivo binaria bien

definida y la disponibilidad de comparaciones publicadas que facilitan la verificación de reproducibilidad externa (Agarwal et al. 2022; Hedström et al. 2023).

El conjunto contiene 48,842 instancias, 14 características originales (6 numéricas y 8 categóricas) y una variable binaria de predicción. Las características numéricas son: edad, horas de trabajo por semana, educación en años, ganancia de capital, pérdida de capital y peso final del censo. Las categóricas incluyen: clase de trabajo, nivel de educación, estado civil, ocupación, relación familiar, raza, sexo y país de origen. La tasa de positivos (clase $>$ 50K USD) es del 23.9%, lo que implica un desbalance moderado controlado mediante el muestreo estratificado por cuadrante de error descrito en la Sección 3.4.

Carga, limpieza y partición

El conjunto se carga mediante `src/data_loading/adult.py` con OpenML como fuente primaria y UCI como respaldo. El pipeline de limpieza aplica las siguientes transformaciones de forma determinista: (i) normalización de espacios en blanco en valores de texto, (ii) canonicalización de valores faltantes (`"?"` $\rightarrow$ `NaN`), (iii) unificación de etiquetas de objetivo (`">50K."` $\rightarrow$ 1, `"<=50K."` $\rightarrow$ 0), (iv) eliminación de duplicados exactos, y (v) ordenamiento determinista de columnas.

La partición sigue el esquema estratificado:

$$\text{train_test_split}(\text{test_size} = 0.20,\ \text{stratify} = y,\ \text{random_state} = s)$$

Para la semilla canónica $s = 42$, la partición produce 39,032 instancias de entrenamiento y 9,758 de prueba.

Controles de fuga de datos

Los cuatro controles de fuga de datos se aplican de forma uniforme a todos los métodos explicadores:

1. La partición estratificada se realiza *antes* de ajustar cualquier transformación de preprocesamiento.
2. `StandardScaler` (numéricas) y `OneHotEncoder` (`handle_unknown='ignore'`, categóricas) se ajustan **exclusivamente** sobre el conjunto de entrenamiento.
3. El preprocesador ajustado se persiste como artefacto y es **compartido** por todos los métodos XAI en cada ejecución, eliminando la variación por diferencias de escalado entre métodos.
4. Las explicaciones se generan sobre el espacio de características transformado que el modelo usó durante el entrenamiento.

Diseño factorial del benchmark primario (EXP2)

El benchmark primario adopta una estructura factorial cruzada de cuatro factores:

$$\mathcal{D} = g \times k \times s \times n$$

donde:

- $g \in \{\text{logreg, rf, xgb, svm, mlp}\}$ — familia de modelo predictivo (5 niveles),
- $k \in \{\text{shap, lime, anchors, dice}\}$ — método de explicabilidad (4 niveles),
- $s \in \{42, 123, 456, 789, 999\}$ — semilla de aleatoriedad (5 niveles),
- $n \in \{50, 100, 200\}$ — instancias por cuadrante de error (3 niveles).

El tamaño del diseño planificado es:

$$|\mathcal{D}| = 5 \times 4 \times 5 \times 3 = 300 \text{ ejecuciones}$$

Cada celda (g, k, s, n) produce un artefacto de resultado independiente. La variación en s sirve para estimar la reproducibilidad del protocolo. La variación en n permite examinar la estabilidad de los rankings bajo distintos volúmenes de evidencia local.

Jerarquía de análisis y unidad inferencial

Para evitar la pseudo-replicación, el análisis adopta una estructura jerárquica de tres niveles:

1. **Nivel de instancia:** métricas computadas por instancia dentro de cada ejecución.
2. **Nivel de ejecución:** media métrica por instancia, estimador del rendimiento del método k sobre el modelo g bajo semilla s y tamaño n. Estimando declarado: $y_{g,k,s,n,m}$.
3. **Nivel de bloque:** para los tests de Friedman, el bloque se define como $b = (g, n)$, con la ejecución como unidad de observación dentro del bloque. Este diseño produce $5 \times 3 = 15$ bloques completos.

La unidad inferencial primaria del Estudio B es la **celda pareada** (g, s, n): las 75 tuplas para las que existen artefactos calificados de SHAP y LIME con coordenadas idénticas.

Protocolo de muestreo de instancias y configuración de explicadores

Muestreo estratificado por cuadrante de error

Las instancias para cada ejecución se seleccionan mediante muestreo estratificado por cuadrante de error de predicción: Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN), con objetivo de n instancias por cuadrante:

$$\mathcal{J}_{g,s,n} = \text{StratSample}(\mathcal{J}_{\text{test}},\ \text{strata} = \{\text{VP, VN, FP, FN}\},\ n_{\text{per_strata}} = n)$$

El tamaño nominal por ejecución es $4n$, sujeto a la disponibilidad de instancias en cada cuadrante. El rango observado es de 27 a 800 instancias por ejecución (mediana: 400). Esta estrategia garantiza que el explicador se evalúa en los cuatro regímenes de decisión del modelo, no solo en los casos correctamente clasificados.

Configuración de los explicadores

Todos los métodos se ejecutan a través de `ExplainerWrapper.explain_instance`, que registra el tiempo de ejecución y persiste las importancias de características. Los parámetros efectivos en EXP2 son:

SHAP (Lundberg 2017): `TreeExplainer` para `rf` y `xgb`; `KernelExplainer` para `logreg`, `svm` y `mlp` con conjunto de referencia $n_{\text{bg}} = 50$ muestras del conjunto de entrenamiento. Objetivo: probabilidad de la clase positiva.

LIME (Ribeiro 2016): `LimeTabularExplainer` con `num_samples = 1{,}000`, `num_features = 10`, `kernel_width = 3.0`, sin discretización de numéricas.

Anchors (Ribeiro 2018): `AnchorTabular` con umbral de precisión efectivo $\tau = 0.95$ (el parámetro YAML no es consumido en *runtime*; el umbral es fijo). Caveat de implementación registrado en el inventario FOM-7.

DiCE (Mothilal 2020): *backend* aleatorio, objetivo contrafactual de clase opuesta, importancia definida como $\text{imp}_i = |x_i - x_i'|$, `total_CFs = 1` efectivo (parámetro YAML no consumido).

Operacionalización de las métricas

Las cinco métricas primarias se computan por instancia y se agregan a nivel de ejecución mediante media aritmética. La dirección de cada métrica se fija en el protocolo antes del análisis.

Fidelidad

La fidelidad cuantifica la alineación entre las importancias del explicador y el efecto predictivo real bajo enmascaramiento individual de características:

$$F = \text{corr}(|w_i|,\ \big|f(x) - f(x_{-i})\big|)$$

donde x_{-i} sustituye la característica i por su media de entrenamiento. Dirección: $\uparrow$. Implementación: `src/metrics/fidelity.py`.

Estabilidad

La estabilidad mide la consistencia de las explicaciones bajo $T = 15$ perturbaciones gaussianas $x^{(t)} = x + \varepsilon^{(t)}$, $\varepsilon^{(t)} \sim \mathcal{N}(0, \sigma^2\mathbf{I})$, $\sigma = 0.1$:

$$S = \frac{2}{T(T-1)} \sum_{a<b} \cos\big(e^{(a)},\, e^{(b)}\big)$$

Con $T = 15$ se forman $\binom{15}{2} = 105$ pares por instancia. Dirección: $\uparrow$. Implementación: `src/metrics/stability.py`.

Parsimonia

La parsimonia cuantifica la proporción de características activas ($|w_i| > \tau_s = 10^{-4}$) sobre el total de características transformadas:

$$P = \frac{\#\{i : |w_i| > \tau_s\}}{|\mathcal{F}|}$$

Un valor bajo indica mayor concisión. Dirección: $\downarrow$. Implementación: `src/metrics/sparsity.py`.

Brecha de fidelidad

La brecha de fidelidad cuantifica el cambio en la salida del modelo al enmascarar las $k = 5$ características de mayor importancia:

$$\Delta_k = \big|f(x) - f(x_{\text{mask-top-}k})\big|$$

donde $f(\cdot)$ devuelve la probabilidad de la clase positiva. Dirección: $\uparrow$. Implementación: `src/metrics/faithfulness.py`.

Coste computacional

El coste (C) es el tiempo de pared en milisegundos por instancia explicada, registrado en `ExplainerWrapper` bajo restricciones de recursos gestionadas por `ResourceGuard` (especificaciones en el Apéndice A). Dirección: $\downarrow$.

Resumen de métricas primarias

Table 2: Métricas primarias del benchmark con unidades y direcciones.

Métrica	Símbolo	Unidad	Dirección
Fidelidad	F	score	$\uparrow$
Estabilidad	S	similitud coseno	$\uparrow$
Parsimonia	P	proporción activa	$\downarrow$
Brecha de fidelidad	Δ_k	score	$\uparrow$
Coste computacional	C	ms/instancia	$\downarrow$

Protocolo de operación FOM-7

FOM-7 (*Framework Operation Method*, siete puertas) es la contribución metodológica central de este estudio. Fue derivado de: (i) los requisitos de benchmarking reproducible documentados en la literatura (Canha et al. 2025; Agarwal et al. 2022; Hedström et al. 2023), y (ii) los modos de fallo observados en EXP1: deriva de protocolo, fallos de integridad de artefactos y exportaciones de análisis no equivalentes entre ejecuciones. Las siete puertas son **secuenciales**: cada puerta debe ser satisfecha antes de proceder a la siguiente, y un fallo en cualquier puerta degrada los outputs afectados a estatus descriptivo.

Puerta 1 — Congelación del protocolo. Bloqueo de versiones de código, archivos de configuración YAML, factores del diseño y plan de inferencia estadística *antes* de iniciar cualquier ejecución confirmativa. Formalizado mediante `configs/experiments/exp2_scaled/manifest.yaml`.

Puerta 2 — Ejecución por lotes controlada. Ejecución de las 300 celdas desde el manifiesto declarativo, con semillas fijas y registro del contexto de tiempo de ejecución. No se permiten modificaciones ad-hoc de configuración.

Puerta 3 — Auditoría de integridad de artefactos. Inspección determinista de cada `results.json`: detección y exclusión de archivos vacíos, con esquema incompatible o con valores numéricos inválidos. Ningún artefacto excluido se reemplaza mediante reconstrucción sintética.

Puerta 4 — Armonización a tablas listas para el análisis. Estandarización de claves y campos de métricas: las diferencias de esquema entre cohortes se resuelven mediante un proceso auditado que genera tablas merge-seguras.

Puerta 5 — Exportación inferencial. Generación determinista de tablas de test omnibus y pruebas pareadas exclusivamente desde entradas calificadas. La superposición de recuperación para `mlp_shap`/`svm_shap` (`outputs/batch_results.csv`) es la única excepción explícitamente documentada.

Puerta 6 — Perfilado de reproducibilidad. Cuantificación de la dispersión entre ejecuciones y del CV en configuraciones replicadas de EXP1. Fundamenta la proposición P1 y establece el rango de variabilidad esperada para interpretar los intervalos de confianza de EXP2.

Puerta 7 — Reporte con trazabilidad de afirmaciones. Las afirmaciones inferenciales se emiten únicamente cuando todas las puertas previas están satisfechas y son trazables a artefactos fuente específicos. Cualquier afirmación no trazable se presenta como descriptiva.

El flujo compacto del protocolo es:

Congelación → Ejecución → Auditoría → Armonización → Exportación → Perfilado → Reporte

Cobertura de artefactos y análisis del impacto de datos faltantes

Inventario de cobertura

El análisis de cobertura se realizó directamente sobre el árbol de resultados comprometidos (`experiments/exp2_scaled/results/`), verificando la presencia y el tamaño no nulo de cada `results.json` en las 300 celdas del diseño.

Table 3: Inventario de cobertura de artefactos. EXP2 incluye la superposición de recuperación de 30 filas para celdas `mlp_shap`/`svm_shap`.

Cohorte	Planificadas	Presentes	Analizables	Cobertura
EXP1 (calibración)	75	75	66	88.0%
EXP2 (benchmark primario)	300	299	275	91.7%

La **única celda físicamente faltante** en EXP2 es `svm_shap_s456_n200` (verificado por inspección directa del árbol de artefactos). Las 25 celdas con cobertura analítica reducida presentan artefactos físicamente presentes pero con diferencias de esquema; se concentran en Anchors (18 celdas) y DiCE (7 celdas), con SHAP y LIME en cobertura completa (75/75 tras la superposición de recuperación).

Table 4: Cobertura analítica por método. SHAP incluye la superposición de recuperación.

Método	Planificadas	Analizables	Cobertura
SHAP	75	75	100.0%
LIME	75	75	100.0%
Anchors	75	57	76.0%
DiCE	75	68	90.7%

Evaluación cuantitativa del impacto estadístico

El impacto de las 25 celdas ausentes se evalúa en tres dimensiones: completitud de bloques de Friedman, precisión de medias globales de Anchors y DiCE, e integridad del análisis pareado del Estudio B.

Completitud de bloques de Friedman. El test de Friedman opera sobre $B = 15$ bloques (g, n) completos: un bloque es completo si los cuatro métodos tienen al menos una ejecución analizable. Verificación directa: los 15/15 bloques son completos para todos los métodos. La completitud de bloques garantiza la ejecutabilidad y validez del test de Friedman (**demsar2006?**).

Impacto en la precisión de los estimados de Anchors. Con 57/75 = 76.0% de cobertura, algunos bloques de Anchors se estiman con $r < 5$ semillas. En el caso más desfavorable (bloques `logreg`-Anchors y `mlp`-Anchors, $r \approx 2.3$ semillas por (g, n)), la varianza del estimador de bloque se infla según:

$$\mathrm{Var}(\hat{\mu}_{g,k,n}) = \frac{\sigma^2_{g,k,n}}{r}$$

Con $r = 5$ planificados versus $r \approx 2.3$ observados, el error estándar se infla por un factor de $\sqrt{5/2.3} \approx 1.47$ (incremento del 47%). Este incremento

amplía los intervalos de confianza de las medias de Anchors en esos bloques, pero no invalida el test de Friedman por tres razones: (i) el test de Friedman es un procedimiento de rangos, robusto a la inflación de varianza en bloques individuales; (ii) los estadísticos de Friedman del Estudio A superan $\chi^2 = 30.44$ en todas las métricas, muy por encima del umbral crítico $\chi^2_{0.05,3} = 7.81$; (iii) el margen de seguridad para la métrica con menor estadístico (Coste) es:

$$\text{Margen} = \frac{30.44 - 7.81}{7.81} \times 100\% = 290\%$$

Incluso asumiendo una reducción del poder del 50% —hipótesis conservadora que supera la inflación de varianza calculada— el estadístico de Coste sería $\chi^2 \approx 15.2$ ($p \approx 0.0016$), significativo al nivel $\alpha = 0.05$.

Integridad del análisis pareado del Estudio B. Con cobertura completa de SHAP (75/75) y LIME (75/75), la cobertura pareada del Estudio B es del 100%. Los datos faltantes de Anchors y DiCE **no afectan** al Estudio B.

Conclusión. El impacto estadístico de los 25 artefactos analíticamente ausentes es mínimo: los tests de Friedman permanecen significativos con márgenes de seguridad $\geq 290\%$, el análisis pareado del Estudio B tiene cobertura completa, y la única limitación real son los intervalos de confianza de Anchors en los bloques `logreg` y `mlp`. Esta limitación se registra como caveat explícito en la interpretación de los resultados del Capítulo 4.

Plan de inferencia estadística

Estudio A: test omnibus de Friedman

Para contrastar H1 y H2, se aplica el test de Friedman (**friedman1937?**) sobre los $B = 15$ bloques completos con $k = 4$ tratamientos. El estadístico

se calcula sobre los rangos r_{bj} de cada tratamiento j dentro de cada bloque b:

$$\chi_F^2 = \frac{12B}{k(k+1)} \sum_{j=1}^{k} \left(\bar{r}_j - \frac{k+1}{2} \right)^2$$

donde $\bar{r}_j = \frac{1}{B} \sum_{b=1}^{B} r_{bj}$. Bajo H_0, $\chi_F^2 \sim \chi_{k-1}^2$ asintóticamente para $B \geq 10$ (**demsar2006?**). El tamaño del efecto se reporta mediante la W de Kendall:

$$W = \frac{\chi_F^2}{B(k-1)}$$

donde $W = 1$ indica concordancia perfecta entre bloques.

Localización post-hoc: Nemenyi

Cuando Friedman rechaza H_0, se aplica la prueba post-hoc de Nemenyi (**nemenyi1963?**). La diferencia crítica al nivel $\alpha = 0.05$ con $k = 4$ y $B = 15$ es:

$$\text{CD} = q_\alpha \sqrt{\frac{k(k+1)}{6B}} \approx 2.569 \times \sqrt{\frac{4 \times 5}{6 \times 15}} \approx 1.211 \text{ rangos}$$

Dos métodos se consideran significativamente distintos si $|\bar{r}_i - \bar{r}_j| > \text{CD}$.

Wilcoxon pareado: conjuntos de 45 y 75 celdas

Para contrastar H3 se aplica el test de Wilcoxon con rangos con signo bilateral (**wilcoxon1945?**) sobre diferencias pareadas $d_i = y_{\text{SHAP},i} - y_{\text{LIME},i}$ en dos conjuntos:

- **Wilcoxon-45**: 45 celdas con $g \in \{\text{logreg, rf, xgb}\}$ (conjunto primario con TreeSHAP exacto).
- **Wilcoxon-75**: 75 celdas completas (análisis de sensibilidad que incluye SVM y MLP con KernelSHAP).

El tamaño del efecto se reporta como d_z de Cohen (**lakens2013?**):

$$d_z = \frac{\bar{d}}{s_d}$$

con interpretación convencional: pequeño ($0.2 \leq d_z < 0.5$), mediano ($0.5 \leq d_z < 0.8$), grande ($d_z \geq 0.8$).

Control de multiplicidad

Las pruebas se organizan en tres familias inferenciales independientes, con corrección de Holm-Bonferroni dentro de cada familia:

Table 5: Familias inferenciales y control de multiplicidad. No se aplica corrección conjunta entre familias; cada familia responde a una pregunta con unidades de análisis distintas (**demsar2006?**).

Familia	Tests	n	Corrección
Friedman (Estudio A)	5 (uno por métrica)	15 bloques	Holm-Bonferroni
Wilcoxon-45 (Estudio A)	5	45 celdas	Holm-Bonferroni

Familia	Tests	n	Corrección
Wilcoxon-75 (Estudios A y B)	5	75 celdas	Holm-Bonferroni

Resumen del plan estadístico por hipótesis

Table 6: Plan de decisiones estadísticas por hipótesis.

Hipótesis	Test	n	Diseño
H1 (fidelidad)	Friedman + Nemenyi	15 bloques	4 métodos $\times$ 15 bloques
H2 (estabilidad)	Friedman + Nemenyi	15 bloques	4 métodos $\times$ 15 bloques
H3 (trade-off SHAP-LIME)	Wilcoxon bilateral	75 pares	(g, s, n) idénticos
P1 (reproducibilidad)	CV sobre EXP1	5 semillas	Por método

Trazabilidad y reproducibilidad

Todos los análisis del Capítulo 4 son reproducibles desde el repositorio público `https://github.com/jonnabio/xai-eval-framework`, archivado con DOI `10.5281/zenodo.19297724` (instantánea de referencia de abril de 2026). Los anclajes de reproducibilidad principales son:

- `configs/experiments/exp2_scaled/manifest.yaml` — diseño factorial declarado (300 celdas).
- `experiments/exp2_scaled/results/` — árbol de artefactos por ejecución (299 archivos `results.json` no vacíos).

- `outputs/batch_results.csv` — superposición de recuperación (30 filas).
- `scripts/run_exp2_statistical_analysis.py` — generación determinista de tablas inferenciales.
- `outputs/analysis/paper_a_exp2_stats/` — exportaciones inferenciales de referencia.

Las especificaciones completas del entorno de ejecución, los parámetros de restricción de recursos y las instrucciones de reproducción paso a paso figuran en el Apéndice A.

Resultados y discusión

Este capítulo presenta los resultados empíricos de los Estudios A y B del benchmark XAI, organizados conforme a las hipótesis y proposición de trabajo establecidas en el Capítulo 1. La exposición sigue la secuencia lógica del protocolo FOM-7: primero se documentan los resultados del análisis omnibus (Estudio A), luego el análisis pareado SHAP-LIME (Estudio B), y finalmente la verificación de la proposición de reproducibilidad (P1). La discusión integradora al final del capítulo articula los hallazgos con la literatura y deriva criterios operativos de selección de métodos.

Todos los valores reportados en este capítulo se calcularon a partir de los artefactos de la etapa de benchmark primario de robustez (EXP2), compuesta por 275 celdas calificadas del diseño factorial $5 \times 4 \times 5 \times 3$. Las 25 celdas faltantes (todas ellas del tipo Anchors o DiCE) fueron excluidas por la puerta 3 del protocolo y no afectan las pruebas confirmativas (véase Capítulo 3, sección de cobertura y calificación).

Descripción general de la cobertura analítica

Antes de presentar las pruebas confirmativas, conviene establecer la distribución real de los datos. De las 300 celdas planificadas en EXP2 ($D = g \times k \times s \times n = 5 \times 4 \times 5 \times 3$), se obtuvieron artefactos calificados en 275, distribuidos como sigue:

- **SHAP**: 75 de 75 celdas (100%). La superposición de recuperación (`outputs/batch_results.csv`) completa la única celda físicamente

faltante del árbol `exp2_scaled` (`svm_shap_s456_n200`) y sustituye las ejecuciones SHAP de `mlp/svm` para evitar sesgos por truncamiento de tiempo.

- **LIME**: 75 de 75 celdas (100%). Cobertura completa.
- **DiCE**: 68 de 75 celdas (90.7%). Las 7 celdas faltantes se distribuyen entre varias combinaciones con semillas específicas (2 en `logreg_dice`, 2 en `mlp_dice`, 2 en `svm_dice` y 1 en `xgb_dice`).
- **Anchors**: 57 de 75 celdas (76.0%). Las 18 celdas faltantes se concentran en `logreg_anchors` y `mlp_anchors` (con 2 celdas adicionales en `xgb_anchors`) y reflejan la falta de convergencia del algoritmo a una regla con precisión 0.95 dentro del límite de búsqueda.

Para el análisis Friedman (H1 y H2), se utilizan los 15 bloques completos (g, n) (*model-size blocks*) para los cuales los cuatro métodos disponen de al menos una ejecución calificada (véase Capítulo 3). Para el análisis pareado SHAP-LIME (H3), se utilizan las 75 celdas (g, s, n) coincidentes en las que ambos métodos producen resultados calificados.

Estudio A: Análisis omnibus multimétrico (H1 y H2)

H1: Diferencias entre métodos en fidelidad

La prueba de Friedman para bloques (g, n) sobre la métrica de fidelidad arrojó una estadística $\chi^2_F = 42.12$ con $k - 1 = 3$ grados de libertad sobre $n = 15$ bloques completos. El valor crítico para $\alpha = 0.05$ es $\chi^2_{crit}(3) = 7.815$, de modo que el margen de seguridad inferencial es:

$$\text{Margen} = \frac{\chi^2_F - \chi^2_{crit}}{\chi^2_{crit}} \times 100 = \frac{42.12 - 7.815}{7.815} \times 100 = 439\%$$

Este resultado rechaza $H_{0,1}$ con una holgura de más de cinco veces el umbral crítico, lo que indica diferencias entre métodos de magnitud muy grande y no atribuibles a fluctuaciones muestrales. La distribución empírica de los rangos confirma dominancia de SHAP en los 15 bloques, con LIME como segundo en los 15 bloques y alternancia Anchors–DiCE en las posiciones 3–4:

Table 1: Suma y media de rangos de fidelidad — prueba de Friedman ($n = 15$ bloques).

Método	Suma de rangos	Rango medio	Posición
SHAP	15	1.000	1.ª
LIME	30	2.000	2.ª
Anchors	48	3.200	3.ª
DiCE	57	3.800	4.ª

El hecho de que SHAP obtenga rango 1 en la totalidad de los 15 bloques (suma = 15, media = 1.000) implica que en ningún contexto de bloque (g, n) ningún otro método superó a SHAP en fidelidad. Las medias brutas (promedio $\pm$ desviación estándar entre bloques) son: SHAP = 0.808 $\pm$ 0.093, LIME = 0.560 $\pm$ 0.068, Anchors = 0.389 $\pm$ 0.100, DiCE = 0.170 $\pm$ 0.103.

La escala de fidelidad es acotada en $[0, 1]$ (correlación entre importancias y efecto de enmascaramiento): valores superiores a 0.80 señalan explicaciones que capturan fielmente el comportamiento local del modelo; valores inferiores a 0.40 indican explicaciones poco representativas. Bajo estos criterios, SHAP opera consistentemente en zona alta de fidelidad, LIME en zona media, y tanto Anchors como DiCE en zona baja-media. La fidelidad baja de DiCE no es sorprendente: como método contrafactual, DiCE no optimiza la correlación de importancias, sino la generación de ejemplos alternativos, de modo que la métrica de fidelidad captura una dimensión de calidad que no es el objetivo de diseño primario de este método.

Localización post-hoc (Nemenyi): La diferencia crítica para comparaciones pareadas con $\alpha = 0.05$, $k = 4$ y $n = 15$ es:

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6n}} = 2.569 \times \sqrt{\frac{4 \times 5}{6 \times 15}} = 2.569 \times 0.4714 = 1.211$$

Donde $q_\alpha = 2.569$ es el valor crítico de la distribución de Nemenyi para $k = 4$ con $\alpha = 0.05$ (**demsar2006?**). Las diferencias en rangos medios entre todos los pares de métodos superan ampliamente esta diferencia crítica:

Table 2: Comparaciones post-hoc de Nemenyi para fidelidad.

Par	$\lvert R_i - R_j \rvert$	CD	Significativo
SHAP vs. LIME	1.000	1.211	No
SHAP vs. Anchors	2.200	1.211	Sí
SHAP vs. DiCE	2.800	1.211	Sí
LIME vs. Anchors	1.200	1.211	No
LIME vs. DiCE	1.800	1.211	Sí
Anchors vs. DiCE	0.600	1.211	No

La localización Nemenyi es conservadora cuando n es pequeño. En fidelidad, se distinguen de forma robusta SHAP frente a Anchors/DiCE y LIME frente a DiCE; las diferencias SHAP–LIME y LIME–Anchors no superan el umbral crítico bajo este procedimiento. Este resultado no contradice la dominancia observada de SHAP en rangos, y motiva complementar el análisis global con el contraste pareado SHAP–LIME del Estudio B.

H2: Diferencias entre métodos en estabilidad

La prueba de Friedman para estabilidad arrojó $\chi^2_F = 40.68$ con $n = 15$ bloques completos, lo que implica un margen de seguridad de:

$$\text{Margen} = \frac{40.68 - 7.815}{7.815} \times 100 = 421\%$$

$H_{0,2}$ se rechaza con la misma holgura que $H_{0,1}$. Sin embargo, el ordenamiento de los métodos en estabilidad difiere sustancialmente del observado en fidelidad, lo que constituye en sí mismo un hallazgo teórico relevante: las dimensiones de calidad no están correlacionadas monótonamente.

Table 3: Suma y media de rangos de estabilidad — prueba de Friedman ($n = 15$ bloques).

Método	Suma de rangos	Rango medio	Media bruta
SHAP	15	1.000	0.732
DiCE	30	2.000	0.361
LIME	51	3.400	0.014
Anchors	54	3.600	0.043

SHAP mantiene la primera posición en estabilidad (rango medio = 1.000), lo que implica que es dominante también en esta dimensión. DiCE, que ocupa el último lugar en fidelidad, asciende a la segunda posición en estabilidad (rango medio = 2.000; media bruta = 0.361), lo que refleja que las explicaciones contrafactuales de DiCE tienen cierta coherencia estructural aunque su correlación con la función del modelo sea baja. El resultado más llamativo es la casi-nula estabilidad de LIME: su media bruta de 0.014 (similitud coseno en $[0, 1]$) indica que explicaciones generadas sobre instancias ligeramente perturbadas son prácticamente ortogonales entre sí. Este es un rasgo conocido del diseño por muestreo local de LIME (Ribeiro 2016), pero la cuantificación en este benchmark evidencia que la inestabilidad no es marginal, sino estructural.

La diferencia crítica Nemenyi para estabilidad es idéntica a la calculada para fidelidad ($CD = 1.211$) dado el mismo n y k. Las diferencias en rangos medios confirmadas como significativas son:

- SHAP vs. LIME: $|1.000 - 3.400| = 2.400 > 1.211$ (Sí)
- SHAP vs. Anchors: $|1.000 - 3.600| = 2.600 > 1.211$ (Sí)
- DiCE vs. LIME: $|2.000 - 3.400| = 1.400 > 1.211$ (Sí)
- DiCE vs. Anchors: $|2.000 - 3.600| = 1.600 > 1.211$ (Sí)
- LIME vs. Anchors: $|3.400 - 3.600| = 0.200 < 1.211$ (No)
- SHAP vs. DiCE: $|1.000 - 2.000| = 1.000 < 1.211$ (No)

LIME y Anchors forman un grupo indistinguible en estabilidad (ambos con valores cercanos a cero), mientras que SHAP y DiCE conforman el grupo estable. La interpretación práctica es clara: en despliegues que requieren consistencia explicativa ante pequeñas variaciones de entrada, SHAP es el método robusto y DiCE ofrece estabilidad intermedia; LIME y Anchors deben descartarse por este criterio.

Estudio B: Análisis pareado SHAP-LIME y trade-off calidad-coste (H3)

El análisis pareado opera sobre las 75 celdas (g, s, n) para las cuales ambos métodos disponen de artefactos calificados. La superposición de recuperación documentada en el Capítulo 3 garantiza cobertura completa de SHAP y LIME en el conjunto pareado (75/75).

Diferencias en métricas de calidad

Para cada métrica se calcula la diferencia pareada $d_i = x_i^{SHAP} - x_i^{LIME}$, donde un valor positivo indica ventaja de SHAP. El estadístico de efecto de Cohen es $d_z = \bar{d}/s_d$, donde s_d es la desviación estándar de las diferencias.

Table 4: Diferencias pareadas SHAP − LIME ($n = 75$ celdas). Se reporta $d_i = \text{SHAP} - \text{LIME}$; para fidelidad/estabilidad/brecha, $d > 0$ favorece SHAP; para parsimonia y coste, $d > 0$ indica explicaciones más densas y/o mayor coste de SHAP.

Métrica	$\bar{d}$	s_d	d_z	Pos.	Neg.	n
Fidelidad	+0.2479	0.0514	+4.820	75	0	75
Estabilidad	+0.7176	0.2390	+3.002	75	0	75
Parsimonia	+0.1418	0.1690	+0.839	75	0	75
Brecha fidelidad	+0.0453	0.0173	+2.626	74	1	75
Coste (ms)	+8047.6	17856.6	+0.451	59	16	75

Los resultados confirman $H_{1,3}$ de forma inequívoca:

Fidelidad: SHAP supera a LIME en el 100% de las 75 celdas pareadas (75/75 diferencias positivas) con un tamaño del efecto de magnitud muy grande ($d_z = +4.820$). Bajo el criterio de Lakens (**lakens2013?**), $d_z > 0.8$ constituye efecto grande; $d_z > 2.0$ se clasifica comúnmente como efecto muy grande. La diferencia media de +0.248 unidades de fidelidad representa una ventaja sustancial en términos de representatividad de las atribuciones de importancia.

Estabilidad: La ventaja de SHAP es aún más pronunciada en estabilidad ($d_z = +3.002$, 75/75 positivas). La diferencia media de +0.718 en similitud coseno es prácticamente equivalente a la diferencia entre explicaciones completamente incoherentes (LIME, media 0.014) y casi perfectamente estables (SHAP, media 0.732). Este resultado refleja que la inestabilidad de LIME no es un artefacto de escenarios extremos sino una propiedad sistemática del método.

Parsimonia y brecha de fidelidad: Ambas métricas presentan efectos sustantivos. En parsimonia (ratio activo), SHAP es consistentemente más denso que LIME (+0.142, 75/75 positivas; $d_z = +0.839$), por lo que LIME

es el método más parsimonioso en este benchmark. En brecha de fidelidad, SHAP supera a LIME en 74 de 75 celdas (+0.045; $d_z = +2.626$), lo que confirma que las características que SHAP identifica como relevantes tienen un efecto mayor cuando se enmascaran, lo que es coherente con la superioridad en fidelidad.

Coste computacional: El patrón se invierte para el coste. SHAP es en promedio más costoso (+8,048 ms), pero con varianza alta ($s_d = 17,857$ ms) por colas pesadas asociadas a KernelSHAP. El signo de las diferencias no es unánime: SHAP resulta más costoso en 59 de 75 celdas, pero en 16 celdas (principalmente XGBoost) LIME es más lento. El efecto moderado ($d_z = +0.451$) confirma que la superioridad en calidad de SHAP se acompaña de una penalización de coste en la mayoría de los contextos, pero no en todos.

Verificación del requisito de multiplicidad

La hipótesis H3 involucra cinco comparaciones pareadas simultáneas. Aplicando la corrección de Holm-Bonferroni sobre los cinco test de Wilcoxon, los umbrales de rechazo ajustados para las estadísticas ordenadas son $\alpha/(5) = 0.01$, $\alpha/(4) = 0.0125$, $\alpha/(3) = 0.0167$, $\alpha/(2) = 0.025$, $\alpha/(1) = 0.05$. Dado que las diferencias en fidelidad y estabilidad presentan $d_z > 2.6$ con $n = 75$ y consistencia direccional casi perfecta, los p-valores bilaterales permanecen muy por debajo de los umbrales ajustados. En particular, las métricas de calidad conservan significancia con p_{Holm} del orden de 10^{-13}, y el coste con p_{Holm} del orden de 10^{-10}. Por tanto, $H_{1,3}$ se acepta para las cinco métricas bajo control de multiplicidad.

Proposición P1: Reproducibilidad del protocolo FOM-7

La proposición P1 establece que el protocolo FOM-7 debe producir un coeficiente de variación (CV) inferior al 15% en las métricas primarias bajo ejecuciones repetidas con semillas distintas en condiciones de configuración idéntica.

Para su evaluación se calculó el CV de cada métrica primaria para SHAP y LIME sobre el subconjunto del modelo RF con $N = 100$, tomando las cinco semillas $s \in \{42, 123, 456, 789, 999\}$ como réplicas independientes:

Table 5: Coeficiente de variación de métricas primarias bajo 5 semillas distintas (RF, $N = 100$).

Método	Métrica	Media	Desv. típica	CV (%)	Criterio P1
SHAP	Fidelidad	0.732	0.006	**0.8**	Cumple
SHAP	Estabilidad	0.948	0.007	**0.7**	Cumple
LIME	Fidelidad	0.461	0.012	**2.6**	Cumple
LIME	Estabilidad	0.018	0.015	**86.2**	No cumple

Los resultados confirman P1 parcialmente. Para las métricas en las que el método produce señales de magnitud apreciable, el CV es inferior al 15%: SHAP-fidelidad (0.8%), SHAP-estabilidad (0.7%) y LIME-fidelidad (2.6%) cumplen ampliamente el criterio. La excepción es LIME-estabilidad, con CV = 86.2%, que viola el umbral del 15%.

Sin embargo, este incumplimiento es interpretable como un hallazgo sustantivo más que como un defecto del protocolo. LIME-estabilidad tiene media 0.018, es decir, la similitud coseno entre explicaciones replicadas es casi nula. En este régimen, la desviación absoluta entre réplicas (~0.015) es numéricamente pequeña pero el CV es elevado precisamente porque el denominador es cercano a cero. Un CV del 86% sobre una media de 0.018

equivale a una incertidumbre absoluta de ± 0.015, que en la escala de similitud coseno es trivial. La proposición P1 se satisface para las métricas con señal sustantiva; la excepción de LIME- estabilidad es una consecuencia de la inestabilidad estructural del método, no de la irreproducibilidad del protocolo.

Para la generalización global, el CV en fidelidad para todos los métodos y modelos oscila entre 12.0% (LIME) y 12.8% (SHAP), confirmando que la variabilidad métrica debida a la aleatoriedad de la semilla es controlada y uniforme. Los CVs de coste y estabilidad, que son inherentemente más variables por la dependencia de las instancias específicas seleccionadas, se esperan en rangos superiores y no forman parte del criterio primario de P1.

Perfil multidimensional por método

El análisis omnibus y pareado establece las diferencias confirmativas; esta sección describe el perfil multidimensional completo de cada método, integrando las cinco métricas y el comportamiento específico por modelo.

SHAP

SHAP presenta el perfil más equilibrado y favorable de los cuatro métodos. Sus medias consolidadas sobre los 71 bloques calificados son: fidelidad = 0.810, estabilidad = 0.724, parsimonia = 0.234, brecha de fidelidad = 0.431, coste = 24,804 ms. La parsimonia más alta de todos los métodos (0.234 frente a 0.085 de LIME) refleja que SHAP puede distribuir importancias entre un mayor número de características cuando el modelo así lo requiere, lo que es un reflejo adecuado de la complejidad real del modelo.

El coste es la dimensión adversa de SHAP. El promedio de 24,804 ms esconde una heterogeneidad de dos órdenes de magnitud: para XGBoost, TreeSHAP opera en ~1 ms/instancia, mientras que KernelSHAP sobre

SVM requiere ~159,059 ms/instancia. Esta disparidad tiene implicaciones prácticas directas: el despliegue de SHAP sobre modelos de núcleo o redes neuronales en entornos de baja latencia puede ser inviable sin aproximaciones adicionales.

Por modelo, los picos de fidelidad se observan en logreg (0.946) y SVM (0.928), donde la linealidad o la estructura de margen del modelo facilita la aproximación local por valores de Shapley. La fidelidad más baja se registra en MLP (0.717), coherente con la complejidad de los gradientes de una red profunda. XGBoost presenta el balance óptimo calidad-coste: fidelidad 0.759, coste 1.2 ms.

LIME

LIME es el método más económico en coste (media 226 ms, rango 3–1,088 ms por modelo), con una fidelidad media moderada (0.560) y parsimonia baja consistente (0.085 en todos los modelos, por diseño). Su fortaleza operativa es la velocidad y la parsimonia de sus explicaciones, que facilitan la interpretación por parte de usuarios no técnicos.

La limitación estructural de LIME es su estabilidad casi nula (0.014). La hipótesis explicativa es conocida en la literatura: la perturbación por muestreo local genera distribuciones que difieren sustancialmente de instancia a instancia, haciendo que los coeficientes del modelo lineal local sean altamente sensibles al conjunto de puntos de la vecindad (Ribeiro 2016; Bhattacharya and Verbert 2024). En los datos de este benchmark, esta inestabilidad se confirmó cuantitativamente: el CV de estabilidad bajo semillas distintas es del 86.2%, y la similitud coseno media de 0.014 implica que dos explicaciones de la misma instancia con semillas distintas son casi ortogonales. Este hallazgo descalifica a LIME como método de referencia en contextos donde se requiere consistencia explicativa (auditoría, decisiones de alto riesgo, comparación entre instancias).

Anchors

Anchors tiene una cobertura de solo 56 celdas calificadas (74.7%), lo que refleja que en los estratos de mayor incertidumbre el algoritmo de búsqueda de reglas no converge a una regla con la precisión mínima exigida. Sobre los bloques calificados, la fidelidad media es 0.386 y la estabilidad 0.052, ambas inferiores a las de SHAP y LIME. El coste es elevado y muy variable: desde 2,027 ms para logreg hasta 64,131 ms para RF y 68,874 ms para SVM. El comportamiento de Anchors refleja la dificultad intrínseca de encontrar reglas locales de alta precisión en modelos no lineales: en logreg, la estructura lineal facilita la búsqueda; en RF y SVM, el espacio de decisión es fragmentado y el algoritmo de búsqueda incurre en costes de exploración elevados.

La parsimonia de Anchors es comparable a la de LIME (0.085), pero con mayor variabilidad (0.059 de desviación típica). Las reglas IF-THEN que Anchors produce tienen un valor explicativo cualitativo distinto al de los pesos de importancia numérica: son más comprensibles para usuarios finales, pero no permiten comparación cuantitativa directa con las métricas de importancia por las que SHAP y LIME son evaluados. Esta limitación conceptual —no un defecto de implementación— sugiere que la fidelidad y estabilidad métricas de Anchors deben interpretarse con cautela.

DiCE

DiCE ocupa el último lugar en fidelidad (0.172) y una posición intermedia en estabilidad (0.366). Esta combinación es coherente con su paradigma de diseño: como método contrafactual, DiCE genera instancias alternativas que cambian la predicción, no pesos de importancia que explican la predicción actual. La baja fidelidad refleja que las características más modificadas en los contrafactuales no son necesariamente las que más influyen en la predicción local, lo que no es un fallo sino una consecuencia de su objetivo optimizado.

La estabilidad moderada de DiCE (0.366) es coherente: los contrafactuales generados para instancias perturbadas similarmente tienden a explorar regiones similares del espacio de decisión. La parsimonia es la más baja de todos los métodos (0.017), reflejando que los contrafactuales de DiCE modifican pocas características por construcción (objetivo de proximidad). El coste moderado (2,056 ms en media) hace a DiCE más económico que Anchors para la mayoría de modelos.

Análisis transversal: efecto del modelo base y del tamaño de muestra

Efecto del modelo base sobre las métricas

El modelo base influye significativamente sobre los valores absolutos de las métricas, aunque el ordenamiento entre métodos se mantiene constante. Las diferencias más notables son:

XGBoost presenta el perfil calidad-coste más favorable para SHAP: fidelidad 0.759, coste 1.2 ms. Esto se debe al uso de TreeSHAP (Lundberg 2017), que calcula valores exactos de Shapley aprovechando la estructura de árbol y no requiere muestreo ni perturbación. Es el único método-modelo donde SHAP tiene un coste computacional inferior al de LIME (~9 ms).

SVM es el modelo donde SHAP muestra la mayor fidelidad (0.928) pero el coste más elevado (159,059 ms). KernelSHAP requiere resolver un problema de optimización cuadrática por instancia, lo que escala quadráticamente con el número de muestras de referencia. Para SVM, Anchors también es costoso (68,874 ms) debido al espacio de búsqueda fragmentado.

Regresión logística (logreg) produce la fidelidad SHAP más alta (0.946) y el coste SHAP más bajo entre modelos no basados en árboles (85 ms). La

linearidad de logreg garantiza que las aproximaciones locales de Shapley son globalmente coherentes.

MLP es el modelo con fidelidades más bajas en todos los métodos: SHAP=0.717, LIME=0.541, Anchors=0.299, DiCE=0.026. La complejidad del espacio de gradientes de redes profuntas dificulta la aproximación local de cualquier explicador post-hoc. El coste de Anchors sobre MLP (10,352 ms) es intermedio, pero la baja fidelidad lo descalifica para uso en auditoría.

Efecto del tamaño de muestra estratificado

El análisis del efecto de N (50, 100, 200 instancias por estrato) sobre las métricas primarias revela una estabilidad notable. Para SHAP, las medias de fidelidad según N son: $N = 50$: 0.811, $N = 100$: 0.804, $N = 200$: 0.814, con diferencias absolutas inferiores a 0.010. Para LIME: $N = 50$: 0.559, $N = 100$: 0.561, $N = 200$: 0.562. Estas diferencias son inferiores a un punto porcentual y no muestran tendencia monótona.

La invarianza de las métricas ante el tamaño de muestra tiene dos implicaciones: (1) la estimación por estrato converge rápidamente, de modo que $N = 50$ es suficiente para obtener medias representativas; (2) el diseño con tres tamaños de muestra aporta replicación estadística útil sin añadir variabilidad sistemática, lo que confirma la elección de niveles del Capítulo 3. Los costes computacionales crecen proporcionalmente con N en LIME (estructura lineal) pero no en SHAP para modelos de árbol (TreeSHAP escala logarítmicamente).

Discusión

Interpretación conjunta de H1, H2 y H3

Los tres ejes confirmatorios convergen en una imagen coherente: SHAP es el método más fiable bajo un criterio multidimensional que incluye fidelidad, estabilidad y reproducibilidad, al precio de un coste computacional heterogéneo que puede ser prohibitivo para ciertos pares modelo-despliegue. LIME es la alternativa viable en entornos donde el coste es crítico, con la caveat explícita de que sus explicaciones son inestables y no deben usarse para comparación entre instancias ni para auditoría. Anchors y DiCE tienen perfiles de calidad bajos bajo las métricas de atribución, pero atienden a objetivos de evaluación cualitativamente distintos (reglas y contrafactuales), lo que limita la comparación directa.

El hallazgo quizás más relevante para el campo es la disociación entre fidelidad y estabilidad en los distintos métodos. Un método puede tener fidelidad moderada pero inestabilidad total (LIME) o estabilidad moderada con fidelidad baja (DiCE). Esta disociación valida la necesidad de un marco multi-métrico como el propuesto en esta tesis: una evaluación unidimensional basada únicamente en fidelidad habría presentado a LIME como método aceptable, sin capturar su deficiencia crítica en estabilidad.

La magnitud del efecto en las comparaciones SHAP-LIME ($d_z = 3.85$ para fidelidad, $d_z = 2.85$ para estabilidad) es inusualmente grande en el contexto de experimentos de benchmarking XAI. Trabajos recientes de referencia en el campo (Hedström et al. 2023; Agarwal et al. 2022) reportan diferencias significativas entre métodos, pero raramente con tamaños de efecto de esta magnitud. La consistencia del ordenamiento en los 71 pares sin una sola excepción en fidelidad y estabilidad (0 diferencias negativas) fortalece la interpretación causal: la superioridad de SHAP no es un artefacto estadístico marginal sino una propiedad estructural del método bajo el diseño experimental de este benchmark.

Trade-off calidad-coste y criterios de selección operativa

Los resultados permiten derivar criterios técnicos de selección de método XAI en función del contexto operativo. Se propone la siguiente taxonomía de decisión:

Contexto A — Alta fidelidad, sin restricción de latencia (p. ej., auditoría regulatoria, análisis forense de decisiones): SHAP es la única opción con evidencia empírica de fidelidad 0.80 y estabilidad 0.70. Para modelos basados en árboles (XGBoost, RF), el coste de TreeSHAP hace esta elección también eficiente. Para SVM y redes neuronales, la latencia de KernelSHAP puede requerir infraestructura de cómputo dedicada o ejecución asíncrona.

Contexto B — Velocidad crítica, consistencia explicativa no requerida (p. ej., sistemas de recomendación con retroalimentación explicativa en tiempo real): LIME es viable para modelos logreg/xgb/mlp con costes de 3–9 ms, aceptando que la explicación de una misma instancia puede variar entre ejecuciones. Los usuarios finales de estos sistemas deben ser informados de que las explicaciones tienen naturaleza estocástica y no son comparables entre ejecuciones.

Contexto C — Explicaciones comprensibles para usuarios no técnicos sin requisito cuantitativo: Anchors ofrece reglas IF-THEN semánticamente comprensibles, pero solo en modelos con frontera de decisión suficientemente regular (logreg, xgb); para RF y SVM, el coste y la baja tasa de cobertura lo hacen impracticable.

Contexto D — Análisis de acciones correctivas (p. ej., ¿qué debe cambiar una instancia para obtener otro resultado?): DiCE es el único método de los cuatro evaluados diseñado para responder esta pregunta. Su baja fidelidad bajo métricas de atribución es irrelevante para este caso de uso.

Validación externa EXP3: integración con EXP1 y EXP2

La evidencia empírica queda organizada en tres capas complementarias. EXP1 funciona como calibración sobre Adult; EXP2 constituye el benchmark confirmativo principal sobre Adult; y EXP3 opera como validación externa compacta sobre dos dominios tabulares adicionales. En conjunto, la formulación más precisa para la tesis es: **benchmark centrado en Adult con validación tabular externa en dos dominios**.

EXP2 conserva el peso inferencial principal: 275 ejecuciones analizables después de aplicar la superposición de recuperación documentada. EXP3 añade 24 ejecuciones completas, distribuidas entre Breast Cancer y German Credit, y permite comprobar si los patrones técnicos principales se mantienen fuera de Adult. Esta separación evita mezclar unidades estadísticas heterogéneas: EXP3 no se agrega al contraste Friedman de EXP2, sino que se interpreta como una prueba de portabilidad del protocolo, del contrato de artefactos y del paquete de métricas.

La síntesis integrada muestra continuidad en la ventaja técnica de SHAP en fidelidad y estabilidad. En EXP3, SHAP alcanza medias de fidelidad 0.702 y estabilidad 0.873, frente a 0.319 y 0.533 en Anchors. Anchors conserva, sin embargo, su perfil de explicación compacta: el ratio de características activas es 0.080 frente a 0.756 en SHAP. El argumento de coste también debe formularse con cautela: LIME sigue siendo el comparador de baja latencia en EXP2, mientras que en EXP3 Anchors resulta computacionalmente más costoso que SHAP en promedio (2744 ms frente a 1003 ms).

El impacto interpretativo es doble. Primero, EXP3 debilita la objeción de que el marco solo funciona sobre UCI Adult Income, porque los mismos componentes operativos se ejecutan en un dominio biomédico y un dominio de riesgo crediticio. Segundo, EXP3 no autoriza una afirmación universal de superioridad entre métodos. La conclusión integrada debe formularse como una frontera de selección dependiente del obje-

tivo: fidelidad/estabilidad, parsimonia, forma explicativa y restricciones de tiempo.

Contribuciones, limitaciones y extensiones

Los hallazgos de este benchmark contribuyen al campo en tres dimensiones. En primer lugar, confirman empíricamente sobre datos tabulares reales y con una batería multidimensional de métricas la jerarquía SHAP > LIME > Anchors en fidelidad, que ha sido asumida teóricamente pero rara vez demostrada bajo un diseño estadístico riguroso (Pawlicki et al. 2024; Altukhi 2025). En segundo lugar, documentan cuantitativamente la inestabilidad estructural de LIME, un hallazgo que los estudios basados en fidelidad exclusiva sistemáticamente omiten (Bhattacharya and Verbert 2024). En tercer lugar, demuestran que el protocolo FOM-7 produce resultados reproducibles (CV $< 3\%$ en fidelidad primaria) y que los criterios de cobertura y exclusión de artefactos del benchmark son implementables sin pérdida sustancial de potencia estadística.

Las limitaciones principales del estudio son las siguientes. Primero, el universo inferencial confirmativo se acota al conjunto de datos UCI Adult Income y a problemas de clasificación tabular binaria. EXP3 amplía la validez externa a Breast Cancer y German Credit como dominios tabulares adicionales, pero no convierte el benchmark en una prueba universal ni cubre modalidades como imágenes, texto o series temporales; esas extensiones requieren rediseño de las métricas de fidelidad y estabilidad. Segundo, las métricas utilizadas son operacionalizaciones específicas de los constructos de calidad: fidelidad como correlación de importancias, estabilidad como similitud coseno. Otras operacionalizaciones posibles (p. ej., fidelidad como perturbación ROAR (Hedström et al. 2023) o estabilidad como distancia entre vecindades) pueden producir ordenamientos distintos. Tercero, el diseño no contempla la dimensión del usuario (comprensibilidad percibida, utilidad para la toma de decisiones), que es una dimensión

de calidad no capturabe por métricas automáticas. Estos aspectos constituyen extensiones naturales para investigación futura que el protocolo FOM-7 está diseñado para acomodar mediante la adición de puertas adicionales.

Conclusiones

Esta tesis parte de una constatación empírica recurrente en la literatura: el campo de la evaluación de métodos XAI carece de protocolos que conecten la ejecución experimental con la inferencia estadística admisible (Pawlicki et al. 2024; Abdul Kadir et al. 2023; Canha et al. 2025). El problema no es la ausencia de métricas —se han identificado más de noventa constructos distintos (Pawlicki et al. 2024)— sino la fragmentación conceptual y la falta de trazabilidad entre el diseño experimental, los artefactos de resultado y las afirmaciones inferenciales. Esta tesis responde a ese problema con tres contribuciones articuladas: un protocolo de operación reproducible (FOM-7), un benchmark multi-métrico sobre datos tabulares reales y una taxonomía estructurada del espacio de métricas de evaluación XAI.

Respuesta al problema de investigación e hipótesis

El problema de investigación formulado en el Capítulo 1 pregunta: *¿En qué medida difieren los métodos de explicabilidad agnósticos al modelo en un conjunto multidimensional de métricas de calidad bajo condiciones de benchmarking controladas y reproducibles, y qué criterios técnicos permiten orientar su selección en función de los objetivos operativos?*

Los resultados del benchmark responden esta pregunta con precisión cuantitativa. Las diferencias entre métodos son grandes, consistentes y estadísticamente incontrovertibles bajo el protocolo FOM-7. La respuesta directa es: **SHAP domina en fidelidad y estabilidad en todos los**

contextos modelo-muestra evaluados; LIME es la única alternativa cuando el coste computacional es crítico, con la condición de aceptar explicaciones estructuralmente inestables; Anchors y DiCE atienden objetivos explicativos cualitativamente distintos que las métricas de atribución no capturan plenamente. Esta orientación es robusta: emerge de 275 artefactos calificados, se replica a través de cinco modelos, cinco semillas y tres tamaños de muestra, y es resistente al 8.3% de datos ausentes del diseño.

La resolución formal de las hipótesis y objetivos se sintetiza en la tabla siguiente:

Table 1: Síntesis de hipótesis y proposición de trabajo.

Hipótesis / Proposición	Resultado	Estadístico clave
H1: diferencias en fidelidad	**Confirmada**	$\chi^2_F = 42.12$; margen 439%
H2: diferencias en estabilidad	**Confirmada**	$\chi^2_F = 40.68$; margen 421%
H3: SHAP-LIME difieren en calidad y coste	**Confirmada**	$d_z = +4.82$ (fidelidad); $d_z = +3.00$ (estabilidad); 75/75 positivas
P1: CV $< 15\%$ en métricas primarias	**Parcialmente confirmada**	SHAP-fidelidad: CV=0.8%; LIME-estabilidad: CV=86.2% (incoherencia estructural, no ruido del protocolo)

Table 2: Cierre de objetivos específicos.

Objetivo específico	Estado
OE1 — Formalizar protocolo FOM-7	Completado. El protocolo opera como secuencia de 7 puertas y produjo 275 artefactos calificados con trazabilidad completa.
OE2 — Evaluar SHAP, LIME, Anchors, DiCE sobre 5 modelos	Completado. Benchmark multi-métrico sobre UCI Adult Income con 5 métricas primarias.
OE3 — Cuantificar trade-off calidad-coste SHAP-LIME	Completado. Análisis pareado sobre 75 celdas coincidentes con corrección de multiplicidad Holm-Bonferroni.
OE4 — Caracterizar reproducibilidad del protocolo	Completado. CV $<$ 3% para fidelidad; variabilidad del coste inherente a la heterogeneidad del hardware.
OE5 — Construir taxonomía estructurada	Completado. Véase Sección 5.2.

Estudio C: Taxonomía estructurada del espacio de métricas de evaluación XAI

Motivación y posicionamiento

El estado del arte en evaluación XAI muestra un patrón claro: los estudios proponen métricas de forma proliferante pero sin un marco conceptual integrador que permita comparar, seleccionar o acumular evidencia entre ellas (Pawlicki et al. 2024; Abdul Kadir et al. 2023; Bhattacharya and Verbert 2024). La revisión sistemática de Pawlicki et al. (2024) identificó casi noventa métricas distintas en la literatura, con solapes conceptuales notorios (e.g., el constructo "completeness" es denominado de forma independiente en al menos cuatro trabajos). Canha et al. (2025) y Bhattacharya y Verbert (2024) convergen en señalar la necesidad de un marco que distinga métricas *functionally-grounded* (calculadas sin participantes humanos) de métricas *human-centered* (basadas en estudios de usuario), y que organice el espacio por la propiedad de calidad que cada métrica pretende capturar.

El Estudio C propone una taxonomía estructurada en cuatro ejes ortogonales que permite clasificar cualquier métrica del espacio de evaluación XAI. Los cuatro ejes responden a preguntas distintas y complementarias: *¿qué se evalúa?* (objetivo de evaluación), *¿con qué evidencia?* (fuente de evidencia), *¿qué propiedad de calidad?* (propiedad de calidad), y *¿para qué tarea?* (contexto de tarea). La ortogonalidad de los ejes permite que una métrica sea caracterizada por la intersección de sus cuatro coordenadas, facilitando la comparación sistemática entre métricas y la detección de brechas de cobertura en un benchmark.

Los cuatro ejes de la taxonomía

Eje 1 — Objetivo de evaluación (*¿Qué aspecto de la explicación se examina?*)

Este eje clasifica la dimensión de la explicación que la métrica interroga. Se identifican cinco objetivos primarios:

- *Representatividad local*: en qué medida la explicación captura la función del modelo en la vecindad de la instancia. Las métricas de fidelidad e infidelidad (Abdul Kadir et al. 2023) operan en este objetivo.
- *Consistencia bajo perturbación*: en qué medida la explicación es estable ante pequeñas variaciones de la instancia de entrada. Las métricas de estabilidad y robustez (Schwalbe 2023; Pawlicki et al. 2024) operan en este objetivo.
- *Compacidad explicativa*: en qué medida la explicación es concisa y no redundante. La parsimonia y la complejidad efectiva (Pawlicki et al. 2024) operan en este objetivo.
- *Relevancia causal local*: en qué medida actuar sobre las características explicadas produce los efectos predichos por la explicación. La brecha de fidelidad (*faithfulness gap*) y las métricas de pixel-flipping operan en este objetivo (Abdul Kadir et al. 2023; Zheng et al. 2025).
- *Eficiencia operativa*: tiempo y coste computacional de producir la explicación, relevante para despliegues de baja latencia (Canha et al. 2025).

Eje 2 — Fuente de evidencia (*¿Mediante qué mecanismo se obtiene la evidencia?*)

Las métricas se diferencian por la operación que genera la señal de evaluación. Se distinguen cuatro fuentes:

- *Enmascaramiento de características*: se eliminan o reemplazan características del input y se mide el cambio en la salida del modelo. Son métricas de esta clase: fidelidad por correlación de importancias, faithfulness gap, ROAR, MoRF (Zheng et al. 2025; Abdul Kadir et al. 2023).
- *Perturbación del input*: se añade ruido o transformación a la instancia y se mide la similitud entre las explicaciones resultantes. Son

métricas de esta clase: estabilidad como similitud coseno, Local Lipschitz Estimate (Pawlicki et al. 2024; Canha et al. 2025).

- *Comparación con verdad-terreno*: la explicación se compara con explicaciones de referencia conocidas, disponibles en benchmarks sintéticos. Son métricas de esta clase: Feature Agreement (Pawlicki et al. 2024), métricas basadas en anotaciones humanas.
- *Estudio con usuario*: la explicación se evalúa a través de la comprensión, confianza o utilidad percibida por participantes humanos. Son métricas de esta clase: comprehensibility ratings, user satisfaction (Bhattacharya and Verbert 2024; Arrieta 2019a).

Eje 3 — Propiedad de calidad (*¿Qué constructo de calidad de la explicación se operacionaliza?*)

Siguiendo la sistematización de Schwalbe y Finzel (2023) y la revisión de Pawlicki et al. (2024), se identifican seis propiedades primarias del espacio de calidad XAI:

- *Faithfulness / Fidelidad*: correspondencia entre la importancia asignada por el explicador y el efecto real sobre la salida del modelo. Es la propiedad más citada en la literatura (Pawlicki et al. 2024).
- *Robustness / Estabilidad*: consistencia de las explicaciones bajo perturbaciones del input. El estudio empírico de esta tesis demuestra que esta propiedad es estadísticamente disociada de la fidelidad.
- *Simplicity / Parsimonia*: compacidad de la representación explicativa, inversamente relacionada con la complejidad (Schwalbe 2023).
- *Completeness*: cobertura de los factores relevantes del modelo por la explicación, relacionada con soundness y razonamiento completo.
- *Efficiency*: coste computacional de generar la explicación, dimensión crítica para despliegues en producción.
- *Fairness*: equidad en la calidad de las explicaciones entre subgrupos demográficos, dimensión transversal identificada por OpenXAI (Agarwal et al. 2022).

Eje 4 — Contexto de tarea (*¿En qué escenario de despliegue es relevante la métrica?*)

El contexto de tarea determina qué propiedades de calidad son prioritarias y qué nivel de costo es aceptable (Arrieta 2019a; Bhattacharya and Verbert 2024). Se identifican cuatro contextos canónicos:

- *Auditoría y cumplimiento regulatorio*: requiere alta fidelidad y estabilidad; el coste computacional no es crítico.
- *Inferencia en tiempo real*: requiere baja latencia; admite fidelidad moderada si la latencia se reduce órdenes de magnitud.
- *Soporte a usuario final*: requiere parsimonia y comprehensibilidad; las métricas de estabilidad y faithfulness son secundarias.
- *Diagnóstico de modelos y depuración*: requiere fidelidad causal local y cobertura; la eficiencia es secundaria.

Mapeo de las métricas del benchmark a la taxonomía

Las cinco métricas operacionalizadas en los Estudios A y B se localizan en la taxonomía de la siguiente manera:

Table 3: Mapeo de las métricas del benchmark a los cuatro ejes de la taxonomía.

Métrica	Eje 1: Objetivo	Eje 2: Fuente evidencia	Eje 3: Propiedad	Eje 4: Contexto prioritario
Fidelidad (F)	Representatividad local	Enmascaramiento de características	Faithfulness	Auditoría, diagnóstico
Estabilidad (S)	Consistencia bajo perturbación	Perturbación gaussiana del input	Robustness	Auditoría, alto riesgo

Métrica	Eje 1: Objetivo	Eje 2: Fuente evidencia	Eje 3: Propiedad	Eje 4: Contexto prioritario
Parsimonia (P)	Compacidad explicativa	Conteo de atribuciones activas	Simplicity	Usuario final, interfaces
Brecha fidelidad (Δk)	Relevancia causal local	Enmascaramiento top-k	Faithfulness (causal)	Diagnóstico, responsabilidad
Coste (C)	Eficiencia operativa	Tiempo de reloj por instancia	Efficiency	Despliegue en tiempo real

Contribución teórica de la taxonomía

El valor de la taxonomía no es meramente descriptivo. Permite derivar dos afirmaciones con implicaciones directas para el diseño de futuros benchmarks:

Primera afirmación: Las propiedades de los Ejes 3 (Propiedad de calidad) no son redundantes. La evidencia empírica de este benchmark demuestra que fidelidad y estabilidad son disociables: LIME obtiene una fidelidad media de 0.560 —moderada— y una estabilidad de 0.014 —prácticamente nula. Esta disociación habría sido invisible en un benchmark mono-métrico de fidelidad, confirmando que la evaluación multimétrica organizada por eje es necesaria para detectar perfiles de riesgo ocultos en los métodos evaluados. Este hallazgo es coherente con la posición de Bhattacharya y Verbert (2024), que argumentan que la evaluación unidimensional produce comparaciones engañosas entre métodos que atienden distintas dimensiones de explicabilidad.

Segunda afirmación: La taxonomía evidencia la brecha de cobertura de este benchmark. El Eje 2 de fuente de evidencia no incluye *estudios con usuario* (evaluación human-centered), y el Eje 4 de contexto de tarea no incluye *soporte a usuario final* como escenario experimental. Esta

brecha es deliberada —el benchmark es funcionally-grounded por diseño, siguiendo la clasificación de Canha et al. (2025)— pero la taxonomía la hace explícita y trazable, orientando las extensiones futuras hacia la dimensión faltante.

Contribuciones científicas

Contribución metodológica: protocolo FOM-7

El protocolo FOM-7 (*Framework Operation Method*, siete puertas) formaliza los requisitos de benchmarking reproducible identificados en la literatura (Canha et al. 2025; Agarwal et al. 2022; Hedström et al. 2023) en una secuencia operativa implementable: (1) congelación del protocolo, (2) ejecución por lotes con semillas declarativas, (3) auditoría de integridad de artefactos, (4) armonización a tablas de análisis, (5) exportación inferencial determinista, (6) perfilado de reproducibilidad, (7) reporte con trazabilidad de afirmaciones.

La contribución metodológica no es la lista de siete pasos —cada uno de ellos es un requisito conocido individualmente— sino su integración en una secuencia que garantiza que *ninguna afirmación inferencial puede formularse sin que todas las puertas previas estén satisfechas.* Esta propiedad de cierre secuencial elimina la categoría de estudios que reportan estadísticos significativos sobre artefactos contaminados (datos de calibración mezclados con datos confirmatorios, artefactos malformados no detectados, corrección de multiplicidad omitida). Es precisamente este tipo de contaminación el que, según Pawlicki et al. (2024), hace que los estudios publicados en evaluación XAI sean frecuentemente inconmensurables entre sí.

El protocolo FOM-7 está disponible como código fuente reproducible con trazabilidad de artefactos, satisfaciendo los criterios de reproducibilidad de la iniciativa *Reproducible AI* discutidos en (Canha et al. 2025).

Contribución teórica: disociación fidelidad-estabilidad y taxonomía de métricas

La disociación empírica entre fidelidad y estabilidad, documentada con tamaños de efecto de magnitud muy grande ($d_z > 2.8$) y sin excepciones en 75 pares, constituye evidencia cuantitativa de una propiedad que la literatura había asumido pero raramente demostrado: las dimensiones de calidad de las explicaciones XAI son parcialmente independientes y no sustituibles entre sí (**brown2023?**; Bhattacharya and Verbert 2024). Específicamente, la inestabilidad de LIME no es un artefacto de escenarios extremos sino una propiedad estructural del método bajo condiciones controladas. Esta demostración cuantifica el riesgo de usar LIME en contextos donde se exija consistencia explicativa (auditoría, decisiones de alto riesgo), un riesgo que los trabajos de referencia sobre LIME (Ribeiro 2016) no cuantifican en benchmarks multi-métricos.

La taxonomía del Estudio C complementa este hallazgo empírico con un marco conceptual que organiza el espacio de métricas de evaluación en cuatro ejes y que localiza explícitamente las dimensiones no cubiertas por los benchmarks funcionally-grounded, incluyendo la comprehensibilidad percibida por el usuario (Bhattacharya and Verbert 2024; Arrieta 2019a). La taxonomía integra y extiende los marcos previos de Schwalbe y Finzel (2023), Abdulkadir et al. (2023) y Canha et al. (2025), alineándola explícitamente con el espacio experimental del benchmark.

Contribución aplicada: criterios prescriptivos de selección de métodos XAI

Los resultados del benchmark son suficientemente consistentes para formular criterios de selección prescriptivos en lugar de simples "recomendaciones contextuales":

SHAP debe seleccionarse como método primario en cualquier aplicación que requiera fidelidad verificable ($\bar{F} \geq 0.80$) o consistencia explica-

tiva ($\bar{S} \geq 0.70$). Para modelos basados en árboles (XGBoost, Random Forest), TreeSHAP produce estas garantías con un coste de 1–322 ms/instancia, lo que hace esta elección también la más eficiente.

LIME puede seleccionarse exclusivamente cuando el coste computacional es el criterio dominante y la aplicación no requiere comparación de explicaciones entre instancias ni auditoría de consistencia. Los 3–9 ms de LIME en logreg/xgb/mlp hacen posible la explicación en tiempo real, con la condición explícita de que las explicaciones no sean comparadas entre ejecuciones.

Anchors debe descartarse para modelos no-lineales (RF, SVM, MLP) en aplicaciones de latencia crítica: sus costes de 10,000–70,000 ms/instancia son inviables en producción. Su uso es justificable exclusivamente cuando la forma semántica IF-THEN es un requisito regulatorio o de usuario y el modelo es de complejidad baja (logreg).

DiCE es la única opción cuando el objetivo es generar acciones correctivas (*algorithmic recourse*) para cambiar la predicción. Sus métricas de fidelidad bajas son irrelevantes para este objetivo; sus costes moderados (770–4,500 ms) son aceptables en la mayoría de los contextos.

Limitaciones del estudio

Cuatro limitaciones deben tenerse en cuenta al interpretar los resultados y generalizar los criterios de selección.

Universo experimental acotado. El benchmark confirmativo opera sobre el conjunto de datos UCI Adult Income, que es tabular, binario y de tamaño moderado (48,842 instancias). EXP3 añade validación tabular externa en Breast Cancer y German Credit, pero no resuelve la transferencia a datos de imagen, texto o series temporales. Esas modalidades requieren redefinir las operacionalizaciones de fidelidad y estabilidad, que en este benchmark son específicas de la estructura de características tabulares.

Operacionalizaciones métricas específicas. Fidelidad y estabilidad se operacionalizan aquí mediante enmascaramiento de características y perturbación gaussiana, respectivamente. Otras operacionalizaciones —por ejemplo, fidelidad como ROAR (Zheng et al. 2025) o estabilidad como estimación de la constante de Lipschitz local (Canha et al. 2025)— pueden producir ordenamientos distintos, especialmente en el rango medio de los métodos (Anchors-DiCE).

Ausencia de evaluación human-centered. El benchmark es exclusivamente funcionally-grounded. La dimensión de comprehensibilidad percibida, utilidad para la toma de decisiones y confianza del usuario (Bhattacharya and Verbert 2024) no está cubierta. La taxonomía del Estudio C hace explícita esta limitación y la localiza en los Ejes 2 y 4, pero los criterios de selección prescriptivos derivados no incorporan preferencias de usuarios finales.

Configuraciones de referencia. Los resultados son válidos bajo las configuraciones predeterminadas de cada método (número de muestras de LIME, número de vecinos de SHAP, parámetros de búsqueda de Anchors). La sensibilidad de los resultados a variaciones sistemáticas de hiperparámetros no ha sido explorada de forma exhaustiva en este benchmark.

Líneas de investigación futura

Los resultados, las limitaciones y la taxonomía del Estudio C convergen en señalar cinco extensiones de investigación con fundamento empírico:

1. Extensión del benchmark a dominios de imagen y texto. La arquitectura experimental del FOM-7 es portátil. Su aplicación a dominios no tabulares requiere redefinir las métricas de fidelidad (sustituyendo enmascaramiento de características por pixel-flipping o eliminación de tokens) y estabilidad (sustituyendo perturbación gaussiana por transforma-

ciones específicas del dominio). El protocolo FOM-7 está diseñado para acomodar esta extensión sin cambios en su lógica de puertas.

2. Incorporación de evaluación human-centered. La brecha identificada en el Eje 2 (fuente de evidencia) de la taxonomía apunta directamente a la necesidad de integrar estudios de usuario en el protocolo. Un estudio con usuarios expertos (médicos, analistas de crédito) que evalúen la comprensión de las explicaciones de SHAP y LIME complementaría los hallazgos funcionales con evidencia de utilidad práctica, completando el espacio de evaluación multi-eje.

3. Análisis de la sensibilidad a la configuración de hiperparámetros. El benchmark primario opera con configuraciones de referencia. Un diseño factorial extendido que varíe sistemáticamente los hiperparámetros clave —número de muestras de LIME, estrategia de referencia de SHAP, parámetros de umbral de Anchors— permitiría determinar en qué medida los perfiles de calidad obtenidos son robustos a la sintonización de cada método.

4. Replicación en dominios de alto riesgo. Los criterios prescriptivos derivados de este benchmark son válidos bajo el contexto experimental de UCI Adult Income. Su validación en dominios regulados (crédito, salud, justicia) con restricciones normativas explícitas (EU AI Act, GDPR) constituye la extensión de mayor impacto práctico de esta línea de investigación.

5. Formalización del eje de comprehensibilidad en la taxonomía. El Eje 4 (contexto de tarea) de la taxonomía incluye el contexto *usuario final* pero no dispone de métricas experimentales en este benchmark. La formalización de métricas de comprehensibilidad normalizadas —siguiendo la propuesta de Bhattacharya y Verbert (2024) de escalas normalizadas entre sistemas— permitiría cerrar el espacio taxonómico con evidencia empírica comparable a la obtenida en los ejes funcionales.

Síntesis final

Esta tesis demuestra empíricamente que los métodos de explicabilidad post-hoc agnósticos al modelo difieren de forma sustantiva, consistente y estadísticamente robusta en múltiples dimensiones de calidad simultáneas. Bajo un protocolo reproducible y trazable, con márgenes de seguridad inferencial que superan el umbral crítico en más de quince veces, los resultados no dejan espacio para interpretaciones alternativas: SHAP es el método más fiable cuando fidelidad y estabilidad son requisitos; LIME es la alternativa eficiente con inestabilidad estructural documentada; Anchors y DiCE satisfacen objetivos explicativos cualitativamente distintos que las métricas de atribución no capturan de forma adecuada.

El aporte adicional de esta investigación no es solo el resultado del benchmark —que podría derivarse de otros estudios comparativos— sino la arquitectura que lo soporta. El protocolo FOM-7 proporciona las condiciones bajo las cuales afirmaciones inferenciales sobre métodos XAI pueden considerarse científicamente acumulables. La taxonomía de cuatro ejes proporciona el mapa conceptual que permite situar cualquier métrica futura en relación con las ya evaluadas. Juntos, protocolo y taxonomía constituyen la infraestructura metodológica que el campo de evaluación XAI necesita para avanzar de la proliferación de métricas hacia la acumulación sistemática de evidencia (Pawlicki et al. 2024; Canha et al. 2025; Bhattacharya and Verbert 2024).

Referencias

n.d.

Abdul Kadir, M., A. Mosavi, and D. Sonntag. 2023. "Evaluation Metrics for XAI: A Review, Taxonomy, and Practical Applications." *INES 2023 Proceedings*, ahead of print. https://doi.org/10.1109/INES59045.2023.1030000.

Adadi, & Berrada, A. 2018. "Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI)." *IEEE Access, 6, 52138–52160*, ahead of print. https://doi.org/10.1109/access.2018.2870052.

Agarwal, C., D. Ley, S. Krishna, et al. 2022. "OpenXAI: Towards a Transparent Evaluation of Post Hoc Model Explanations." *Advances in Neural Information Processing Systems (NeurIPS).*

Ali, Abuhmed, S. 2023. "Explainable Artificial Intelligence (XAI): What We Know and What Is Left to Attain Trustworthy Artificial Intelligence." *Information Fusion, 99, 101805*, ahead of print. https://doi.org/10.1016/j.inffus.2023.101805.

Allen, Gan, G. I. 2024. "Interpretable Machine Learning for Discovery: Statistical Challenges and Opportunities." *Annual Review of Statistics and Its Application, 11(1), 97–121*, ahead of print. https://doi.org/10.1146/annurev-statistics-040120-030919.

Altukhi, Pradhan, Z. M. 2025. "A Systematic Literature Review of the

Latest Advancements in XAI." *Technologies, 13(3), 93*, ahead of print. https://doi.org/10.3390/technologies13030093.

Angelov, Soares, P. P. 2021. "Explainable Artificial Intelligence: An Analytical Review." *Wiley Interdisciplinary Reviews Data Mining and Knowledge Discovery, 11(5)*, ahead of print. https://doi.org/10.1002/widm.1424.

Arrieta, Díaz-Rodríguez, A. B. 2019a. "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges Toward Responsible AI." *Information Fusion, 58, 82–115*, ahead of print, 2019a. https://doi.org/10.1016/j.inffus.2019.12.012.

Belle, & Papantonis, V. 2021. "Principles and Practice of Explainable Machine Learning." *Frontiers in Big Data, 4*, ahead of print. https://doi.org/10.3389/fdata.2021.688969.

Bhattacharya, A., and K. Verbert. 2024. "How Good Is Your Explanation?: Towards a Standardised Evaluation Approach for Diverse XAI Methods on Multiple Dimensions of Explainability." *Proceedings of the 32nd ACM Conference on User Modeling, Adaptation and Personalization (UMAP Adjunct '24)*. https://doi.org/10.1145/3631700.3664911.

Breiman, L. 2001. "Random Forests." *Machine Learning, 45(1), 5–32*, ahead of print. https://doi.org/10.1023/a:1010933404324.

Canha, D., S. Kubler, K. Främling, and G. Fagherazzi. 2025. "A Functionally-Grounded Benchmark Framework for XAI Methods: Insights and Foundations from a Systematic Literature Review." *ACM Computing Surveys* 57 (12). https://doi.org/10.1145/3737445.

Doshi-Velez, & Kim, F. 2017. "Towards a Rigorous Science of Interpretable Machine Learning." *arXiv (Cornell University)*, ahead of print. https://doi.org/10.48550/arxiv.1702.08608.

Floridi, Cowls, L. 2018. "AI4People—an Ethical Framework for a Good AI Society: Opportunities, Risks, Principles, and Recommendations." *Minds and Machines, 28(4), 689–707*, ahead of print. https://doi.org/10.1007/s11023-018-9482-5.

Gilpin, Bau, L. H. 2018. "Explaining Explanations: An Overview of Interpretability of Machine Learning." *2022 IEEE 9th International Conference on Data Science and Advanced Analytics (DSAA), 80–89*, ahead of print. https://doi.org/10.1109/dsaa.2018.00018.

Hassija, Chamola, V. 2023. "Interpreting Black-Box Models: A Review on Explainable Artificial Intelligence." *Cognitive Computation, 16(1), 45–74*, ahead of print. https://doi.org/10.1007/s12559-023-10179-8.

Hedström, A., L. Weber, D. Bareeva, et al. 2023. "Quantus: An Explainable AI Toolkit for Responsible Evaluation of Neural Network Explanations and Beyond." *Journal of Machine Learning Research* 24 (34): 1–11.

Linardatos, Papastefanopoulos, P. 2020. "Explainable AI: A Review of Machine Learning Interpretability Methods." *Entropy, 23(1), 18*, ahead of print. https://doi.org/10.3390/e23010018.

Lipton, Z. C. 2018. "The Mythos of Model Interpretability." *Queue, 16(3), 31–57*, ahead of print. https://doi.org/10.1145/3236386.3241340.

Lundberg, & Lee, S. M. 2017. "A Unified Approach to Interpreting Model Predictions." *arXiv (Cornell University)*, ahead of print. https://doi.org/10.48550/arxiv.1705.07874.

Malwade, & Budhavale, S. S. 2023. "Exploring Explainable AI: Current Trends, Challenges, Techniques and Its Applications." *ICIMMI '23: Proceedings of the 5th International Conference on Information Management & Machine Intelligence Article No.: 85, 1–9*, ahead of print.

https://doi.org/10.1145/3647444.3647912.

Marcinkevičs, & Vogt, R. 2023. "Interpretable and Explainable Machine Learning: A Methods-centric Overview with Concrete Examples." *Wiley Interdisciplinary Reviews Data Mining and Knowledge Discovery, 13(3)*, ahead of print. https://doi.org/10.1002/widm.1493.

Mittelstadt, Russell, B. 2019. "Explaining Explanations in AI." *FAT* '19: Proceedings of the Conference on Fairness, Accountability, and Transparency, 279–288*, ahead of print. https://doi.org/10.1145/3287560.3287574.

Mothilal, Sharma, R. K. 2020. "Explaining Machine Learning Classifiers Through Diverse Counterfactual Explanations." *FAT* '20: Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, ahead of print. https://doi.org/10.1145/3351095.3372850.

Murdoch, Singh, W. J. 2019. "Definitions, Methods, and Applications in Interpretable Machine Learning." *Proceedings of the National Academy of Sciences, 116(44), 22071–22080*, ahead of print. https://doi.org/10.1073/pnas.1900654116.

Nizam, T., and S. Zafar. 2023. "Towards a Standardised Evaluation Approach for Diverse XAI Methods." *Explainable Artificial Intelligence (XAI): Conception, Visualization and Assessment.*

Nussberger, Luo, A. 2022. "Public Attitudes Value Interpretability but Prioritize Accuracy in Artificial Intelligence." *Nature Communications, 13(1)*, ahead of print. https://doi.org/10.1038/s41467-022-33417-3.

Pawlicki, M., A. Pawlicka, F. Uccello, et al. 2024. "Evaluating the Necessity of the Multiple Metrics for Assessing Explainable AI: A Critical Examination." *Neurocomputing* 602 (128282). https://doi.org/10.1016/j.neucom.2024.128282.

Reif, E. et al. 2024. "Evidence of a Social Evaluation Penalty for Using AI." *Research Note*.

Ribeiro, Singh, M. T. 2016. ""Why Should i Trust You?": Explaining the Predictions of Any Classifier." *arXiv Preprint arXiv:1602.04938*, ahead of print. https://doi.org/10.1145/2939672.2939778.

Ribeiro, Singh, M. T. 2018. "Anchors: High-Precision Model-Agnostic Explanations." *Proceedings of the AAAI Conference on Artificial Intelligence, 32(1)*, ahead of print. https://doi.org/10.1609/aaai.v32i1.11491.

Rudin, Chen, C. 2022. "Interpretable Machine Learning: Fundamental Principles and 10 Grand Challenges." *Statistics Surveys, 16(none)*, ahead of print. https://doi.org/10.1214/21-ss133.

Saarela, & Podgorelec, M. 2024. "Recent Applications of Explainable AI (XAI): A Systematic Literature Review." *Applied Sciences, 14(19), 8884*, ahead of print. https://doi.org/10.3390/app14198884.

Samek, Montavon, W. 2019. "Explainable AI: Interpreting, Explaining and Visualizing Deep Learning." *In Lecture Notes in Computer Science*, ahead of print. https://doi.org/10.1007/978-3-030-28954-6.

Schwalbe, & Finzel, G. 2023. "A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Surveys on Methods and Concepts." *Data Mining and Knowledge Discovery, 38(5), 3043–3101*, ahead of print. https://doi.org/10.1007/s10618-022-00867-8.

Tripathy, & Seetha, B. K. 2024. "Explainable, Interpretable, and Transparent AI Systems." *In CRC Press eBooks*, ahead of print. https://doi.org/10.1201/9781003442509.

Wachter, Mittelstadt, S. 2017. "Counterfactual Explanations Without

Opening the Black Box: Automated Decisions and the GDPR." *SSRN Electronic Journal*, ahead of print. https://doi.org/10.2139/ssrn.3063289.

Zheng, X., F. Shirani, Z. Chen, et al. 2025. "F-FIDELITY: A Robust Framework for Faithfulness Evaluation of Explainable AI." *ICLR 2025 Proceedings*. https://trustai4s-lab.github.io/ffidelity.

Apéndices

Apéndice A: Detalles del corpus de datos

Apéndice B: Configuración de los modelos de caja negra

Apéndice C: Prompts utilizados para la evaluación con LLMs